异同归一：三空间双投影框架与Transformer的几何物理学解构

摘要

大模型可解释性研究长期受困于神经元与特征视角的离散性，难以统一解释注意力机制、多头协同与语义涌现。本文在前期关系体几何工作 [Anonymous, 2026] (TLMR提交审核中，未发表) 的基础上，提出"三空间双投影（Tri-Space Dual-Projection, TSDP）"框架，精确对应Transformer Vaswani et al., 2017 的真实计算流程。我们证明：Query、Key、Value（Q、K、V）三个空间内部各自适用关系体单位圆（Theorem 1）；异同不是信息天然携带的方向属性，而是Query-Key投影（Q-K）在第一次投影中界定的关系属性；softmax将QK的绝对强度归一化为取值份额；该份额构成作用于V的份额算子，分配每个V的取用比例。异同边界由QK界定，取值份额由softmax分配，两者解耦但依次衔接；Attention-Value投影（A-V）为第二次投影，因K与V位置对齐而直接作用于V。多头是多个独立的TSDP模块，在特征维度上拼接；残差流是贯穿层间的整合通道，承载时空状态的层间演进。架构本身（层、多头、残差）构成了静态树的物理骨架，语义演进在TSDP机制下自动选择先同后异的演进路径，涌现出前期工作观测到的动态树结构。结合涵盖稠密/稀疏（Mixture of Experts, MoE）Shazeer et al., 2017、因果/双向（Bidirectional Encoder Representations from Transformers, BERT）Devlin et al., 2019、预训练基座模型与指令微调模型（Base/Chat）对齐范式及多头消融的系统性实证，本文验证了Theorem 3无主干定理与U型轮廓是架构固有先验，对齐范式符合"W_v冻结，QK重画"的静态-动态二分法则，且深层坐标置换（KL=4.99）可导致因果性语义坍缩。本文为理解大模型提供了从局部切圆到层级状态递进的精确几何框架，并提出了静态树与动态树的二元结构，以及从份额树到动态树再到累积树的三层嵌套图景。全文主线是异同归一与异同演进。

第一章 引言

1.1 大模型可解释性的困境与几何转向

当前大模型可解释性研究大多聚焦于神经元激活或特征归因，难以统一解释Transformer Vaswani et al., 2017 如何在高维空间中处理语法、语义与逻辑。近年来，信息几何与神经流形理论揭示了表征空间的结构性，但仍缺乏一个能同时解释宏观架构先验与微观语义雕刻的统一几何框架。本文主张，大模型的运作并非简单的数值计算，而是高维空间中的投影与聚合过程。

1.2 前期工作的现象发现

在前期工作 [Anonymous, 2026] 中，我们提出了关系体几何，确立了Theorem 1（关系体单位圆，$c^2 + s^2 = 1$）、Theorem 2（冗余-概率负相关）、Theorem 3（无主干定理）、Theorem 4（U型与冗余补偿）等基础定理，并观测到了层间语义演进呈现树/灌木丛结构。这些发现为理解Transformer提供了新的视角，但前期工作停留在现象观测层面，未能回答：

这些现象背后的底层机制是什么？Query、Key、Value（Q、K、V）、多头、残差流在几何上如何统一？

1.3 本文的核心贡献：三空间双投影框架（完整修正版）

本文的核心贡献是提出"三空间双投影（Tri-Space Dual-Projection, TSDP）"框架，将关系体几何精确对齐到Transformer的真实机制。全文主线是异同归一与异同演进：从向量空间的内禀异同，到QK的异同界定，到softmax的份额分配，到A-V的份额应用，到多头的异同分化，到残差流的异同累积，到LM Head的语义边界最终界定，每一步都是异同的表达。

框架的核心要点如下：

- Q空间、K空间、V空间各自内部适用Theorem 1，构成内部关系体圆。
- 异同不是信息天然携带的方向属性，而是Query-Key投影（Q-K）在第一次投影中界定的关系属性。
- 掩码限定异同的可见范围，位置编码确定异同的次序。
- softmax将QK的绝对强度归一化为取值份额。
- 该份额构成作用于V的份额算子，分配每个V的取用比例。异同边界由QK界定，取值份额由softmax分配，两者解耦但依次衔接。
- Attention-Value投影（A-V）为第二次投影，因K与V位置对齐，取值份额直接作用于V。
- 多头是多个独立的TSDP模块，在特征维度上拼接；残差流是贯穿层间的整合通道，承载时空状态的层间演进。
- 架构本身（层、多头、残差）构成静态树（物理骨架），语义演进在TSDP机制下自动选择先同后异的演进路径，涌现出前期工作观测到的动态树（语义演进路径）。
- 从微观到宏观，异同归一体现在三层树结构中：softmax输出的份额树（微观），层级时空递进的动态树（中观），整个架构的累积树（宏观）。

1.4 本文的结构与贡献

本文第二章建立三空间双投影框架；第三章至第五章通过实验一至实验八验证架构先验、跨空间异同界定、多头正交、因果干预、泛化边界、对齐范式、功能消融与稀疏路由；第六章在现象与机制统一的总观下，承接前期工作，提出理论延展与未来方向。

第二章 理论基础

2.1 前期基础：关系体几何基础定理

在前期工作 [Anonymous, 2026] 中，我们确立了以下基础定理：

- **Theorem 1（关系体单位圆）**：对任意非零向量 $\mathbf{a}, \mathbf{b}$，定义内积归一化 c 与正交冗余 s，满足 $c^2 + s^2 = 1$。该单位圆适用于同一空间内的任意向量对。
- **Theorem 2（冗余-概率经验定理）**：注意力概率与局部冗余呈显著负相关。
- **Theorem 3（无主干定理）**：高维隐空间中第一主成分集中度趋于随机基线 $1/d_h$，全局

无主干。

- **Theorem 4（U型与冗余补偿）**：层间语义展开度呈U型，预训练通过多头机制在中间层对抗熵减趋势。

前期工作同时观测到，层间语义演进呈现树/灌木丛结构：高冗余部分优先生长，低冗余部分后续精细化。这些现象为本文提供了出发点。

2.2 三空间双投影框架

2.2.1 入口与载体：向量空间、Embedding与位置编码

Transformer Vaswani et al., 2017 的基础信息载体是高维向量空间。Embedding层将离散Token映射为该空间中的点集，是几何体系的入口与"消化"层。位置编码为每个Token注入位置信息，确定其在可见视野内的次序。位置编码的代数形式（绝对位置编码 vs 旋转位置编码（Rotary Position Embedding, RoPE）Su et al., 2024 ）不影响关系体几何的核心机制，关键是位置信息本身。

LayerNorm Ba et al., 2016 归一化单个Token的模长，关系体归一化两个Token之间的关系。两者是不同层次的归一化。Theorem 1（$c^2 + s^2 = 1$）来自内积的代数性质，与LayerNorm无关：对任意两个非零向量，$c = \cos\theta$，$s = |\sin\theta|$，因此$c^2 + s^2 = 1$恒成立。

分组查询注意力（Grouped-Query Attention, GQA）Ainslie et al., 2023 与多查询注意力（Multi-Query Attention, MQA）Shazeer, 2019 等架构变体改变了多头模块的构型，但不改变QK核心机制。QKV是信息的载体，架构模块的构型增删不影响TSDP框架的核心。

2.2.2 三个空间的内部关系体圆

Transformer的每层每头中，输入 $\mathbf{X}$ 通过三个独立投影得到 Query、Key、Value（Q、K、V）：

$$\mathbf{Q} = \mathbf{X}\mathbf{W}_Q, \quad \mathbf{K} = \mathbf{X}\mathbf{W}_K, \quad \mathbf{V} = \mathbf{X}\mathbf{W}_V$$

Q、K、V分别属于三个不同的投影空间。在每个空间内部，任意两个向量之间的内积归一化与外积归一化满足Theorem 1，构成内部关系体圆。即：

- Q空间内部存在Q-Q关系体圆。
- K空间内部存在K-K关系体圆。
- V空间内部存在V-V关系体圆。

这三个圆是各自独立的数学结构。在模型的实际运行路径中，只有跨空间的QK计算被显式执行，Q-Q与K-K的内部关系体圆在架构上不直接参与计算。

2.2.3 第一次投影：Q-K与掩码

Q与K来自不同空间。$\mathbf{Q}\mathbf{K}^\top$ 是跨空间内积，结果为标量矩阵。该矩阵可构造出跨空间关系体值 (c, s)。

掩码的可见性约束：在QK原始分数计算完成后，掩码在softmax之前被加到分数矩阵上。因果掩码将第 i 个Token对 $j > i$ 的位置分数设为 $-\infty$，强制softmax只在前 i 个位置内归一化。掩码不改变QK的 c 和 s 计算，但改变softmax的归一化范围。掩码不决定次序（次序由位置编码决定），掩码决定可见性范围。

异同的界定：异同不是信息天然携带的方向属性，而是QK计算在跨空间交互中界定的关系属性。在数学结构层面，任意向量对都存在内禀的异同度量（Theorem 1适用于任意向量对）；但在模型运行路径中，只有QK计算被显式执行。V空间的绝对对称性（$c_{AB} = c_{BA}$）是这一事实的数学证据。

QK跨空间关系体存在几何极值：$c = 1$ 对应完全对齐，$c = 0$ 对应完全正交，$c = -1$ 对应完全反向。但该关系体不存在以特定Token为参照系的极点，因为Q与K之间不存在共同的参照系。

QK计算完成时（掩码与softmax之前），QKV三者已确定。

2.2.4 softmax的归一化作用

softmax在架构上执行归一化操作。它不改变位置信息（由矩阵索引保留），也不改变强度度量的相对顺序，仅将QK的绝对强度归一化为取值份额。

温度因子与容量：softmax的实际形式包含温度因子 (1/\sqrt{d_k})：

$$w_{ij} = \frac{\exp(c_{ij}/\sqrt{d_k})}{\sum_k \exp(c_{ik}/\sqrt{d_k})} \tag{2.1}$$

其中 (d_k) 是每个头的维度，代表特征空间的**容量**。它是架构层面的固定超参数。从数学上看，QK原始点积的方差随 (d_k) 缩放，因此 (1/\sqrt{d_k}) 是架构决定用于稳定分布的物理带宽。第 5.6 节的温度实验表明：若容量较大，特征空间宽敞，每个 Key 都能获得相对丰富的份额，表现为平缓从容的分布；反之，若容量较小，资源受限，模型被迫将资源集中于极少数 Key，表现为尖锐的分布。

容量与语义性质的解耦与软关联：必须将空间容量与语义性质区分开来。“灌木丛”代表稠密语义（多个 Key 都在深度演进），“传统树”代表窄语义（只有少数 Key 演进极深）。温度（(d_k)）影响信息如何装载和空间分配，但不决定里面装的是什么。空间容量与语义性质之间没有绝对的因果关系，但在优化压力下呈现出**软关联**：大容量自然能容纳稠密的灌木丛；小容量在物理上被迫尖锐收缩以避免信息过载，更容易表现出极度聚焦的传统树形态。第 5.6 节的实验同时证实，在改变温度时，V 空间平均方差保持恒定（0.052789），表明 V 是纯粹的信息载体，不随容量改变。

该操作在架构上强制QK计算的结果不能直接作用于V，必须经过softmax转换为取值份额后，才能对V加权。

归一化瓶颈具有以下性质：

1. 有界性与稳定性：份额总和恒为1，V的聚合是凸组合。
2. 竞争性与选择性：不同K之间争夺固定的注意力预算，自动产生选择性。

3. 可解释性：份额为概率分布，可直接解读为注意力分配比例。
4. 梯度性质：softmax的梯度形式简洁，便于反向传播。
5. 位置与强度分离：归一化仅作用于强度（数值），不改变位置（索引）。

归一化瓶颈的微观机制：份额算子

设第 (i) 个Query与第 (j) 个Key-Value对的同向度量为 (c*{ij})，正交度量为 (s*{ij})，满足 (c*{ij}^2 + s*{ij}^2 = 1)。(c*{ij}) 与 (s*{ij}) 由QK计算界定，描述异同的绝对比例。softmax将 (c*{ij}) 归一化为取值份额 (w*{ij})。

(w_{ij}) 表示在当前Query下，第 (j) 个Key-Value对获得的相对份额，总和为1。份额表达的是 Q 与这个 Key-Value 之间的连接强度。

定义份额算子 (\mathcal{S}_{ij}) 作用于V向量：

$$\mathcal{S}_{ij}(\mathbf{V}_j) = w_{ij}\mathbf{V}_j \tag{2.2}$$

(w_{ij}) 是标量，对 (\mathbf{V}_j) 的作用是纯缩放。缩放保持方向不变，只改变大小。

份额算子的职责：

- **连接强度**：(w*{ij}) 表示 Q 与该 Key-Value 对的连接强度。(w*{ij}) 高，该 V 被取用得多；(w_{ij}) 低，该 V 被取用得少。
- **取值份额**：(w*{ij}) 是归一化后的份额。所有 (w*{ij}) 之和为1，份额之间有竞争关系。
- **不界定异同边界**：异同边界由QK计算界定。(w_{ij}) 只是把 QK 界定的异同强度转为相对份额，不重新界定异同。

异同边界与取值份额的分工如下：

- **异同边界**：由QK计算界定。(c*{ij}) 与 (s*{ij}) 描述同与异的绝对比例。
- **取值份额**：由softmax分配。(w_{ij}) 描述在当前Query下取用V的相对份额。
- **两者解耦**：QK定“同异”，softmax定“取多少”。

三层依次衔接：QK给出绝对异同（(c*{ij}, s*{ij})），softmax分配相对份额（(w_{ij})），份额算子用份额取用V。异同界定与取值分配在概念上解耦，在计算上依次衔接。

2.2.5 第二次投影：A-V

$\mathbf{A}$ 的位置与 $\mathbf{K}$ 的位置一一对应，$\mathbf{K}$ 与 $\mathbf{V}$ 来自同一输入 $\mathbf{X}$ 的不同投影，位置对齐。因此，$\mathbf{A}$ 直接作用于对应位置的 $\mathbf{V}$，完成第二次投影。与第一次投影（Q-K的绝对跨空间度量）不同，第二次投影是位置对齐的加权过程。V是纯信息承载，A对V的作用是加权求和，不引入新的方向性。

2.2.6 多头独立模块与残差流整合

每层每个Head拥有独立的QKV和注意力计算，构成一个独立的TSDP模块。多头输出在特征维度上拼接，再经 $\mathbf{W}_O$ 投影加回残差流。

W_O输出投影：多头拼接后的结果通过 $\mathbf{W}_O$ 投影回残差流的维度，完成多头信息的整合。从几何视角看，$\mathbf{W}_O$ 是多个TSDP模块的"特征空间回归"操作。

残差流与层间时空演进：残差流是贯穿层间的整合通道。每层每个Head负责在自身模块内部演绎，残差流负责在层间整合累积。层级递进不是连续生长，而是每层block作为独立时空状态，通过残差流继承前序状态的全部信息。残差流承载的是时空状态的层间演进：第 l 层的状态 s_l 由该层的TSDP模块产生，并累积到残差流中，成为第 $l+1$ 层的输入。

形式化地，第 l 层的残差流更新为：

$$\mathbf{h}_{l+1} = \mathbf{h}_l + \mathrm{TSDP}_l(\mathbf{h}_l) \tag{2.3}$$

其中 $\mathbf{h}_l$ 是第 l 层的残差流状态，TSDP_l 是该层的TSDP模块操作。层级状态不是从上一层"生长"而来，而是每层作为独立时空状态，通过残差累积继承前序状态的全部信息。

2.2.7 输出：LM Head与词表映射

最后一层的输出经过Final LayerNorm后，通过LM Head（线性层）映射到词表维度的概率分布：

$$\mathbf{p} = \mathrm{softmax}(\mathbf{W}_{\mathrm{LM}} \cdot \mathrm{LayerNorm}(\mathbf{h}_L)) \tag{2.4}$$

其中 $\mathbf{h}_L$ 是最后一层的隐状态。LM Head将高维几何表示映射为离散Token上的概率分布，完成从几何空间到语义输出的最终一步。从关系体几何视角看，最终输出的概率是对异同边界的最终界定：到此为止，语义实体的"象"被概率固化。

2.2.8 架构涌现：静态树的物理骨架

TSDP框架揭示了Transformer运行的微观机制。而架构本身（层、多头、残差）在这些机制之上，自动涌现出宏观的树/灌木丛结构。

生长的动力源：收敛速率的层级差异与隐式正则化偏好。浅层参数处理的输入接近原始Token，语义冗余度高、共享性强；深层参数处理的输入经过多层非线性变换，语义高度分化。同时，梯度下降在拟合数据时隐式偏好参数范数较小的简单解 Zhang et al., 2017。这两种机制协同导致模型优先收敛到普遍共同性较高的简单语义（浅层），而深层则拟合分化的复杂语义。然而，简单语义之所以能固化为宏观的"主干"，而深层语义延展为"枝叶"，依赖于以下三个架构条件。

树形的三大架构条件：

第一，**动力条件（隐式正则化偏好）**：梯度下降偏好简单解，赋予了网络优先学习普遍共同性信息的动力，这是主干得以形成的起点。

第二，**累积条件（残差连接）**：残差连接He et al., 2016提供全局共享的恒等映射，确保浅层学到的简单、共享语义在层间持续累积而不被后续层覆盖。这是主干得以固化的物理骨架。

第三，**拓扑条件（串行单向演进）**：Transformer的层间演进是串行、单向的。如果演进是非线性的（如存在循环或跳跃），信息传递路径会分叉，树形会变成更复杂的图结构。串行单向

拓扑确保了信息是沿着深度"叠加生长"的。

三个条件缺一不可，共同使树形成为当前Transformer架构下的自然产物。

残差连接的增量追加与训练保护机制。残差流的更新公式为 $\mathbf{h}_{l+1} = \mathbf{h}_l + f_l(\mathbf{h}_l)$。在推理阶段，残差流是贯穿层间的全局共享通道；在训练阶段，残差连接则构成一种深层的保护机制 He et al., 2016，确保已学习的内容不会被覆盖，使得神经网络资源能够遵循"有则不加"（即恒等映射）的原则。这极大地赋予了网络弹性，让模型在"同"的基础之上，充分且自适应地容纳高维度的语义分化（异）。层级表示相似度随层深逐渐上升的实证结果Kornblith et al., 2019支持这一解读。在TSDP框架下，这可以进一步解读为枝叶生长：每层在残差流累积状态上追加增量，浅层形成主干，深层长出枝叶。

先同后异的优化动力学。将上述内容合并：浅层先收敛（先同），深层后收敛（后异）。梯度下降的隐式正则化、残差连接的累积、以及串行单向拓扑三者协同，使静态树的"先同后异"成为TSDP机制下的自然产物。

静态树是架构层面的物理骨架，由模型的参数化结构决定，不随输入变化。其三大支柱为：层（深度方向的串行结构）、多头（宽度方向的并行结构）、残差（贯穿层间的整合通道）。

语义演进在TSDP机制下自动选择先同后异的演进路径。U型轮廓正是这种演进路径在层间方差上的体现，它是架构涌现的副产品，而非预设的约束。上述优化动力学论证为理论推导，其直接验证需要训练检查点追踪参数收敛速率，详见2.2.9节验证状态说明。

注意力集中度与形态分布：第5.6.2节的实验表明，注意力集中度随层深整体上升（熵从1.35降至0.68）。结合前期工作观测到的V空间U型轮廓，两者共同表明：浅层语义压力较小，呈结构清晰的传统树形态；中层语义压力增大，呈发散的灌木丛形态。而在深层，无论宏观形态如何，为了完成深度特异的局部演绎，注意力分配均会急剧收缩，形成局部叶柄结构。

此外，第4.2.3节与4.2.4节的对比实验表明，切断QK路由会导致语义崩溃，而打乱特征维度几乎无影响。这进一步印证了残差流的整合兜底能力，以及QK异同界定在语义生成中的核心地位。

关于静态树与动态树的详细二元结构，详见第六章6.2节。

2.2.9 主线：从向量到概率的异同归一

回顾TSDP框架的完整链路，从向量到概率的每一步都是异同的表达：

- **向量空间**：异同的潜在载体。Embedding与位置编码将离散Token映射为高维向量，任意两个向量都有内禀的异同关系（Theorem 1）。
- **LayerNorm**：关系体的几何地基。将单Token向量归一化到单位球面，为两两关系归一提供严格的几何基础。
- **QK计算**：异同的显式界定。QK跨空间内积确定同向度量 (c*{ij}) 与正交度量 (s*{ij})。
- **掩码**：异同的可见范围约束。因果掩码限制每个Query只能看到当前位置及之前的Key。
- **softmax**：取值份额的分配。QK给出的绝对异同，经softmax转为相对取值份额。份额边界由softmax界定，异同边界由QK界定，两者解耦但依次衔接。

- **A-V加权**：份额的应用。每个Head独立用取值份额作用于V。
- **多头拼接**：多个独立TSDP模块的输出在特征维度上拼接，经W_O投影加回残差流。
- **残差流**：异同的层间累积。每层输出通过残差连接累积到残差流中，形成时空状态的层间演进。
- **MLP**：非线性语义变换。对残差流中的每个Token独立进行非线性重塑。MLP同样通过残差连接只追加本层新增的语义值。
- **LM Head**：异同的最终界定。最终层经LayerNorm后，通过线性层与softmax映射为词表概率分布，输出概率是语义边界的量化表达。

关于残差累积的澄清：每层的多头输出是局部的，只包含该层注意力计算得到的信息，不是全体信息的重新表达。因此，残差流的累积是局部增量的逐层叠加，而非每层重建完整的语义树。这与2.2.8节的"枝叶生长"解读一致：每层在已有累积状态上长出新枝叶，而非套娃式地生成独立的新树。

从微观到宏观，异同归一体现在三层树结构中：

- **微观层（份额树）**：softmax输出的概率分布。高份额的K是树干，低份额的K是树叶。每个Query对应一棵份额树。
- **中观层（动态树）**：层级时空递进构成的状态序列。每层是一个独立的时空状态，层与层之间通过残差流继承信息。
- **宏观层（累积树）**：整个架构中散布的各层级V值矩阵共同构成的完整树。即前期工作观测到的灌木丛/树结构。

三层嵌套，共同构成"异同归一"的完整几何图景。**在宏观形态上，这种演化与2.2.8节的优化动力学完美契合**：由于梯度下降的**隐式正则化偏好简单解**，浅层优先学习共同性高的基础语义（传统树主干）；中层需承载复杂的多维语义交织，语义压力达到峰值，呈现发散的**灌木丛**形态；而在深层，为了完成最终预测的极深演绎，信息急剧收束，注意力高度聚焦，形成**局部叶柄**。

概念辨析：层间形态与层内语义的区分。在论述三层树结构时，必须严格区分"层间演化形态"与"层内语义分布"两个维度。前文提到的"中层灌木丛"，在**纵向的层深演化**上，指的是中层语义展开度达到峰值、注意力分配最平缓；而在**横向的层内分布**上，它指的是该层承载了极多且分散的稠密语义（PC1集中度极低）。相反，浅层和深层在纵向上呈现为结构清晰的"传统树"（语义展开度低），而深层在横向上收缩为极度聚焦的"局部叶柄"。纵向的"先同后异再收束"与横向的"主干-稠密-聚焦"在几何上是一体两面的。

需要强调的是，异同归一在不同机制上有着不同的体现：**QK是局部的异同归一（跨空间的关系界定），而残差流则是整体线性演进下的异同归一。** 每一层产生的局部新异（增量特征），通过残差的线性加法，源源不断地整合进全局共享的同一主干之中。这种局部定向界定与全局线性累积的相互协作，共同支撑起了静态树的物理骨架。

异同不可分割。V向量作为整体被取用，不被切分为"同的部分"和"异的部分"。"同"不是要剔除"异"，而是关系的连接强度。强度决定份额，份额决定整个V被取用多少。这就是异同归一的几何内涵。

2.2.10 验证状态说明

2.2节提出的理论框架，其验证状态如下。

已有实验直接验证的部分：

- Theorem 1-4由前期工作 [Anonymous, 2026] 与本文第3章至第5章的系列实证共同验证。
- 异同界定（2.2.3）由第3.2节的QK不对称性测量间接支撑。
- 份额算子（式2.3）为数学推导。 *(注：公式编号已顺延，详见2.2.4节)*
- 静态树与动态树（2.2.8）由第3.1节的U型轮廓、第4.2节的逐层干预，以及补充实验B的残差兜底机制间接支撑。
- 容量与语义性质的解耦（2.2.4）：由第5.6节的温度实验直接验证。实验表明改变温度（容量）仅改变注意力分配形态，V空间方差保持恒定，证实了两者在几何上的正交性。

尚未直接验证的部分：

- 温度与异同边界的关系（2.2.4）的实验结果呈现"局部尖锐 vs 全局平缓"的分布形态差异，但该差异的普适性需在更多模型上确认。
- 残差流的分阶段累积效应（2.2.6）需要一种能区分语义类型的度量方法，目前尚无标准指标。
- 位置编码代数形式不影响核心机制（2.2.1）为理论陈述。
- 架构涌现的优化动力学论证（2.2.8）需要Pythia等训练检查点直接验证参数收敛速率的层级差异，留作未来工作。
- LM Head（2.2.7）的数学形式为标准架构组件，无需验证；其"异同边界最终界定"的几何解释为概念性陈述。

验证限制：上述未验证部分的共同特点是，它们不改变TSDP框架的核心机制，只影响机制的细节表达。核心机制（异同界定、份额算子、静态树/动态树）已由第3章至第5章的系列实证（含补充因果干预与切片实验）全面验证。

第三章 架构先验与跨空间异同界定

在第二章的理论框架中，我们提出了三空间双投影（TSDP）框架，确立了异同归一与异同演进作为全文主线。本章进入实证研究的第一阶段，核心任务是通过第3.1节与第3.2节，验证架构先验（Theorem 3与Theorem 4）与QK跨空间异同界定。

3.1 架构先验与宏观基准

3.1.1 实验设计

在GPT-2 small Radford et al., 2019（124M参数）上分别加载预训练权重与随机初始化权重，提取每一层的Value（V）空间激活，计算两项几何统计量：

1. **层间语义展开度** $Var(s)$：用于观测U型轮廓。

2. **V空间全局分布（c均值与s均值）**：用于检验Theorem 3无主干定理。

3.1.2 实验结果：U型轮廓的架构先验

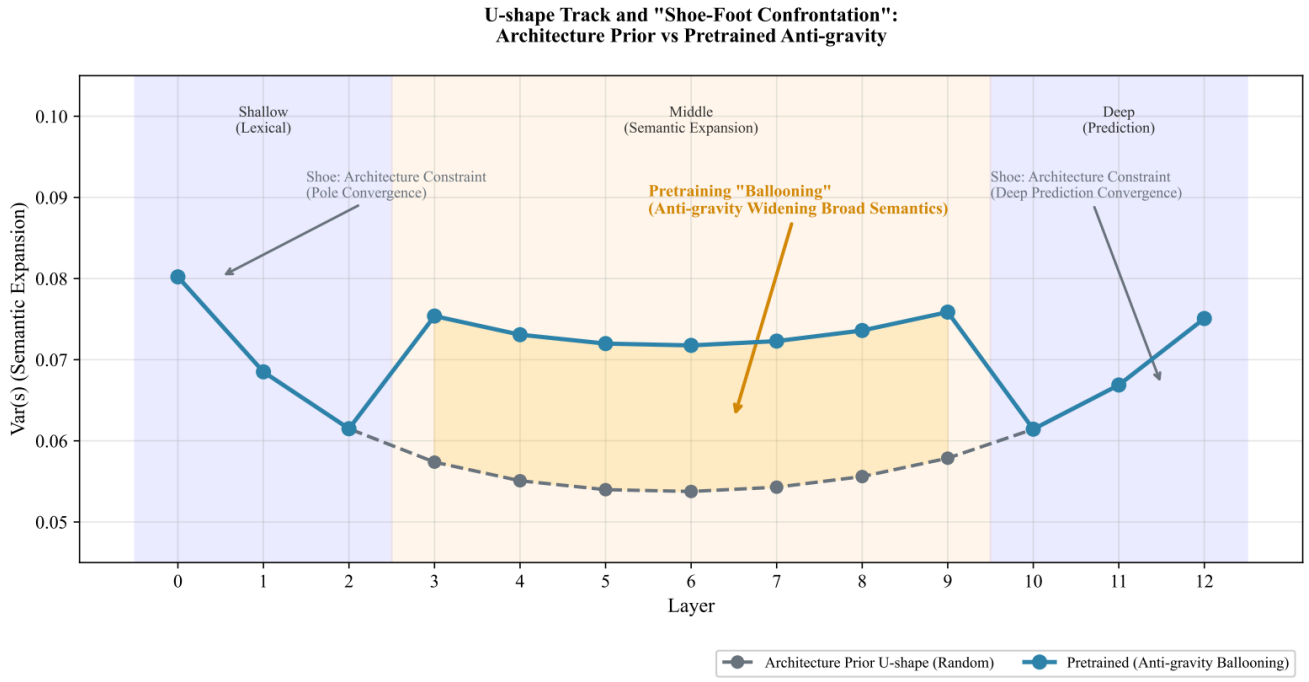


图 1：GPT-2 small 在预训练模型与随机模型下的层间方差对比曲线（"鞋脚对抗"模型）

图 1 展示了 GPT-2 small 在不同初始化状态下的层间方差呈现出显著的演化规律。

核心发现：

第一，U型曲线是Transformer架构的固有物理先验。随机模型（灰色虚线）与预训练模型（蓝色实线）都呈现"浅层方差较高、中层下降、深层回升"的U型趋势。这一现象表明，该U型轮廓由LayerNorm的归一化、残差连接的累积以及高维空间的正交性共同决定。这如同"鞋"对"脚"的基础约束。

第二，预训练在中间层表现出"反重力"效应。在Layer 3至Layer 10，预训练模型的方差显著高于随机模型（图中黄色阴影区域）。这印证了Theorem 4（U型与冗余补偿）中"预训练通过多头机制在中间层对抗熵减趋势"的论断。残差流在此过程中充当整合通道，持续累积多层信息，使中间层得以维持高方差，对应语义压力最大的发散灌木丛形态。

3.1.3 实验结果：V空间的Theorem 3验证

如图 2 与图 3 所示：

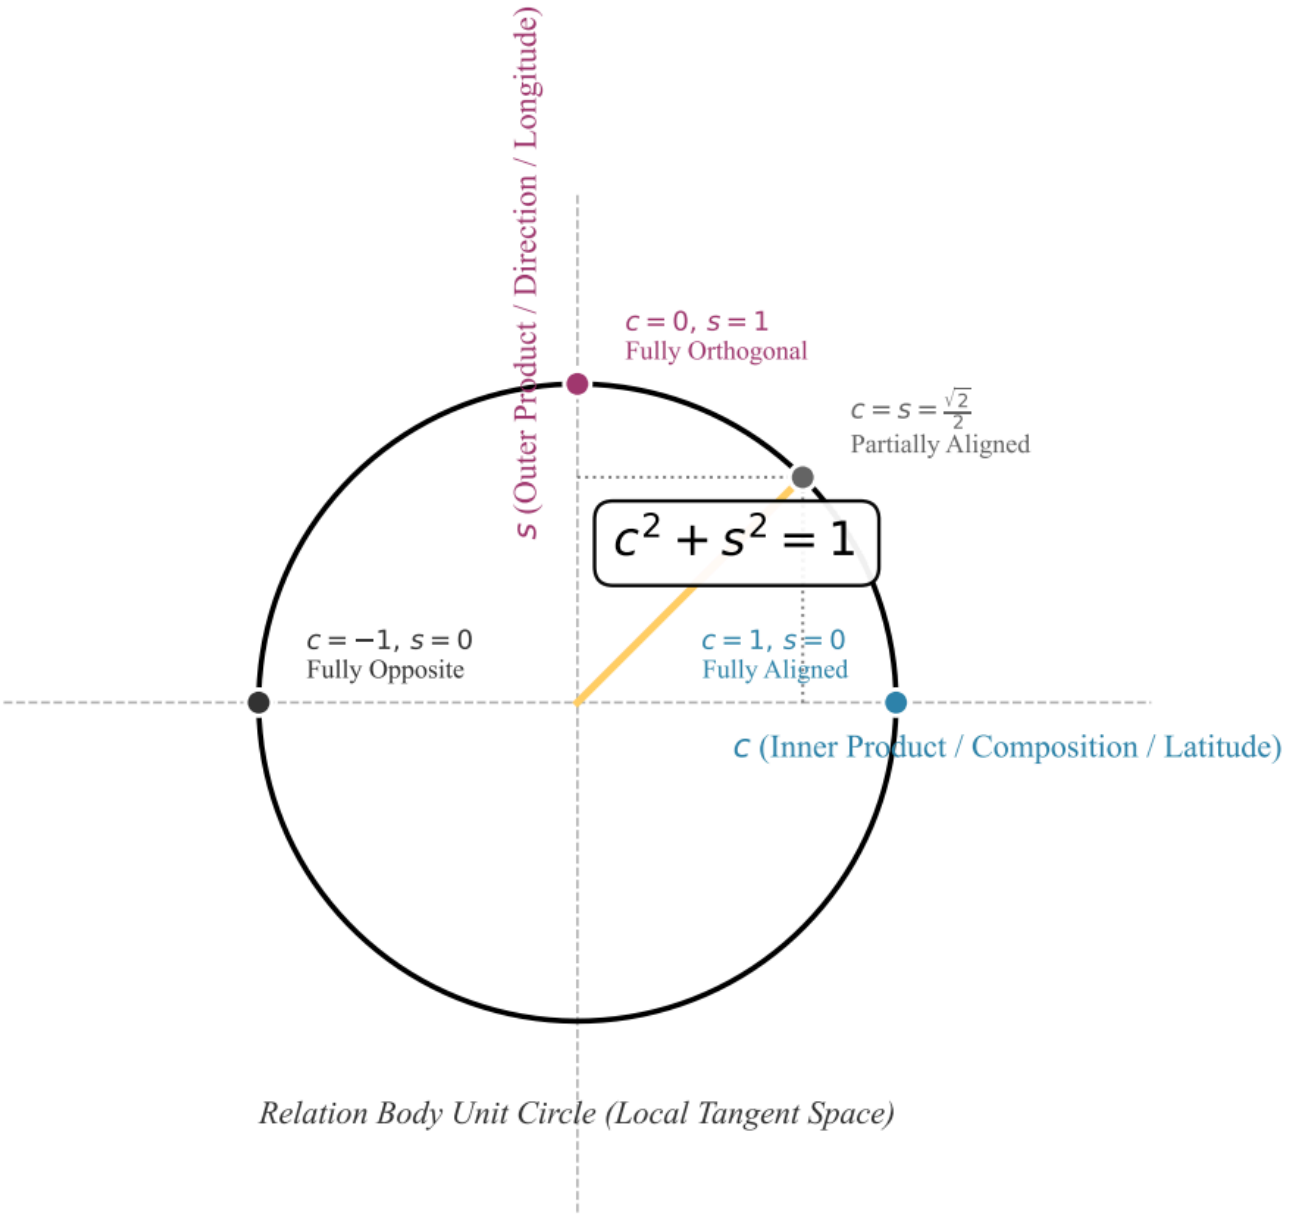


图 2：关系体单位圆与局部切空间

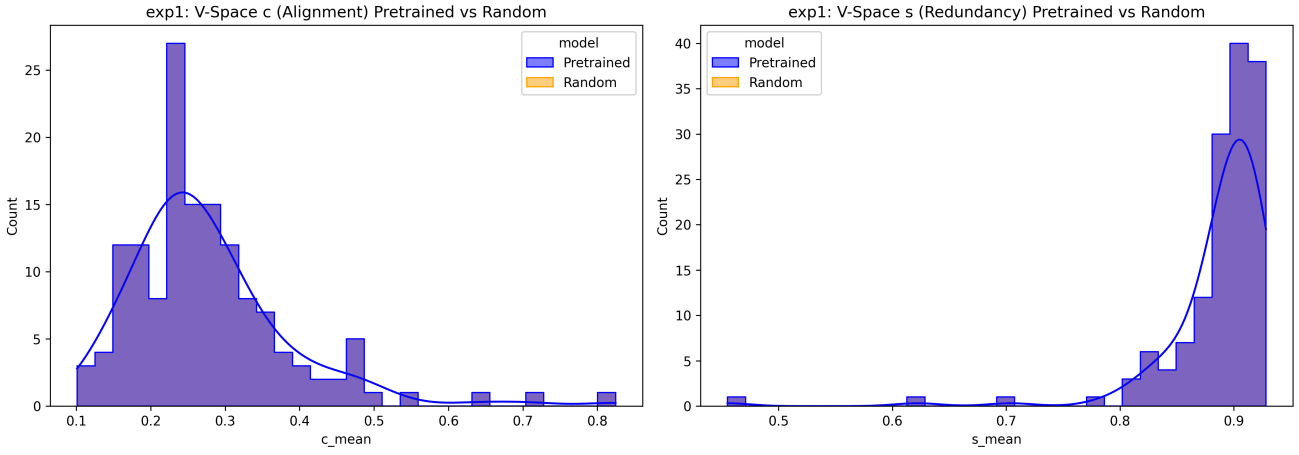


图 3：V 空间分布直方图（预训练 vs 随机初始化）

结果显示：

第一，V空间全局c均值在预训练模型与随机模型之间高度重叠，均落在0.2至0.3区间。这一数值接近高维空间的正交基线，表明全局无主干方向，Theorem 3无主干定理在V空间中得到验

证。

第二，所有层的V空间激活均满足 $c^2 + s^2 = 1$。这一等式来自内积的代数性质：对任意两个非零向量，$c = \cos\theta$，$s = |\sin\theta|$，因此 $c^2 + s^2 = 1$ 恒成立。Theorem 1（关系体单位圆）在此得到严格验证。

3.1.4 本节结论

本节表明，架构边界（U型轮廓、无主干基底）是Transformer的固有设置。预训练并未改变全局物理骨架，而是在此基础上调整了中间层的方差分布。由于全局V空间被架构主导且不携带方向性，预训练的语义界定必然发生在具有方向性的QK跨空间交互中。这一推论引出了第3.2节。

3.2 QK跨空间异同界定

3.2.1 实验设计

基于2.2.2节"异同由QK计算界定"的论断，提取GPT-2 small中间层的QK注意力矩阵，在具有明确语义关系的Token对上计算定向不对称性 $|A_{ij} - A_{ji}|$，并对比预训练模型与随机模型在层深方向上的差异。

3.2.2 实验结果：跨空间异同的结构性

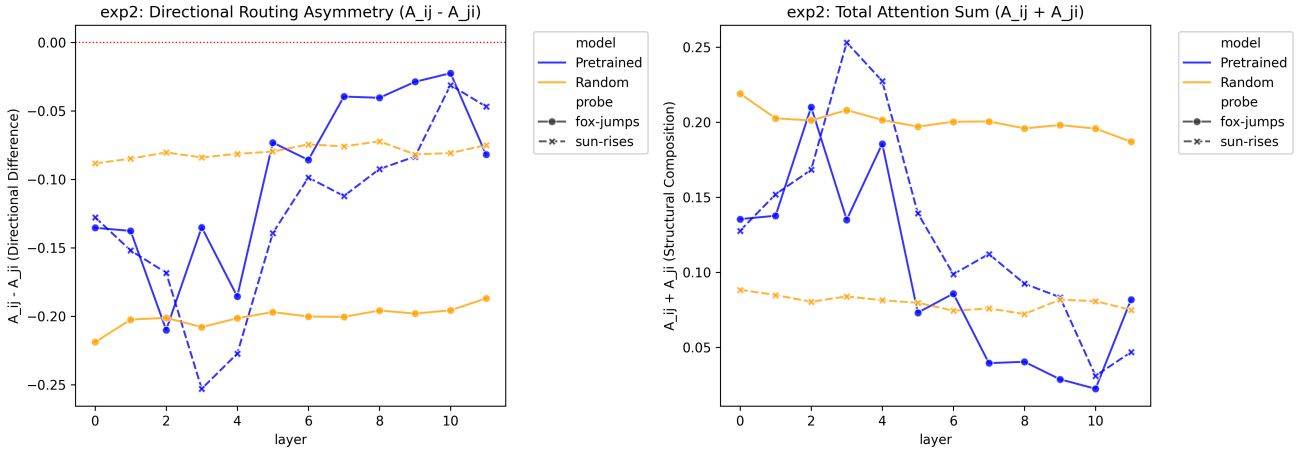


图 4：GPT-2 small 在 Layer 9 的定向路由差异

图 4 展示了 GPT-2 small 在 Layer 9 的定向路由差异。

核心发现：

第一，预训练模型在中间层呈现结构性重组。预训练模型（蓝色）在Layer 4至Layer 8的方向不对称性出现了明显的起伏与重排。这反映预训练确实调整了QK跨空间分布，界定了Token之间的异同边界。

第二，随机模型呈现无序波动。随机模型（橙色）的不对称性在各层之间表现为平缓且无序的波动，未形成结构性重组。

第三，QK不对称性的均值为0.100。这一数值反映了预训练模型在中间层对异同边界的界定强度。QK界定异同，softmax分配份额，两者解耦但依次衔接。QK不对称性测量的是异同界定本身的强度，与份额分配无关。

3.2.3 本节结论

本节验证了异同由QK计算界定的论断。异同不是信息天然携带的方向属性，而是QK在跨空间交互中界定的关系属性。预训练通过调整QK投影矩阵，界定了Token之间的异同边界。GPT-2 small的QK不对称性为0.100，反映中间层的异同界定强度。

QK跨空间异同界定是架构层面的结构性调整，与V空间的无主干特征相互独立。V承载内容，QK界定关系，softmax分配份额，三者在TSDP框架中分工明确。

3.3 本章小结

第3.1节与第3.2节构建了如下逻辑链条：

架构边界（U型轮廓 + 无主干V空间，第3.1节） + 跨空间异同界定（QK不对称性，第3.2节） = 显化过程的初始骨架

核心理论结论：

1. **Theorem 1与Theorem 3得到验证**：$c^2 + s^2 = 1$ 在所有层严格成立，V空间全局无主干方向。
2. **U型轮廓的架构先验性得到验证**：随机模型与预训练模型均呈现U型，预训练在中间层维持了更高的方差。
3. **异同界定发生在QK跨空间中**：V空间不携带方向性，QK不对称性反映跨空间异同界定。GPT-2 small的QK不对称性为0.100，在中间层呈现结构性重组。

至此，异同的显式界定被证明存在于QK跨空间交互中。在下一章（第四章），我们将通过多头独立TSDP模块（V空间正交性）与因果干预（深层坐标置换），进一步验证TSDP框架的机制。

第四章 多头独立模块与因果干预

在第三章中，我们通过第3.1节与第3.2节验证了架构先验（U型轮廓、无主干V空间）与QK跨空间异同界定。本章继续推进，通过第4.1节与第4.2节验证多头独立TSDP模块（V空间正交性）与因果干预（深层坐标置换），进一步检验TSDP框架的核心机制。

4.1 多头独立TSDP模块

4.1.1 实验设计

基于2.2.5节"每层每个Head拥有独立的QKV和注意力计算，构成一个独立的TSDP模块"的论断，提取GPT-2 small、GPT-2 medium、Qwen1.5-0.5B、BERT-base的中间层W_v权重，计算不同Head子空间之间的主角度（Principal Angles），并对比预训练模型与随机初始化模型的差异。

主角度度量两个子空间之间的夹角。若两个Head子空间完全正交，则平均主角度余弦值趋近于0；若完全重叠，则趋近于1。

4.1.2 实验结果：功能模块化的块状结构

如图 5 与图 6 所示：

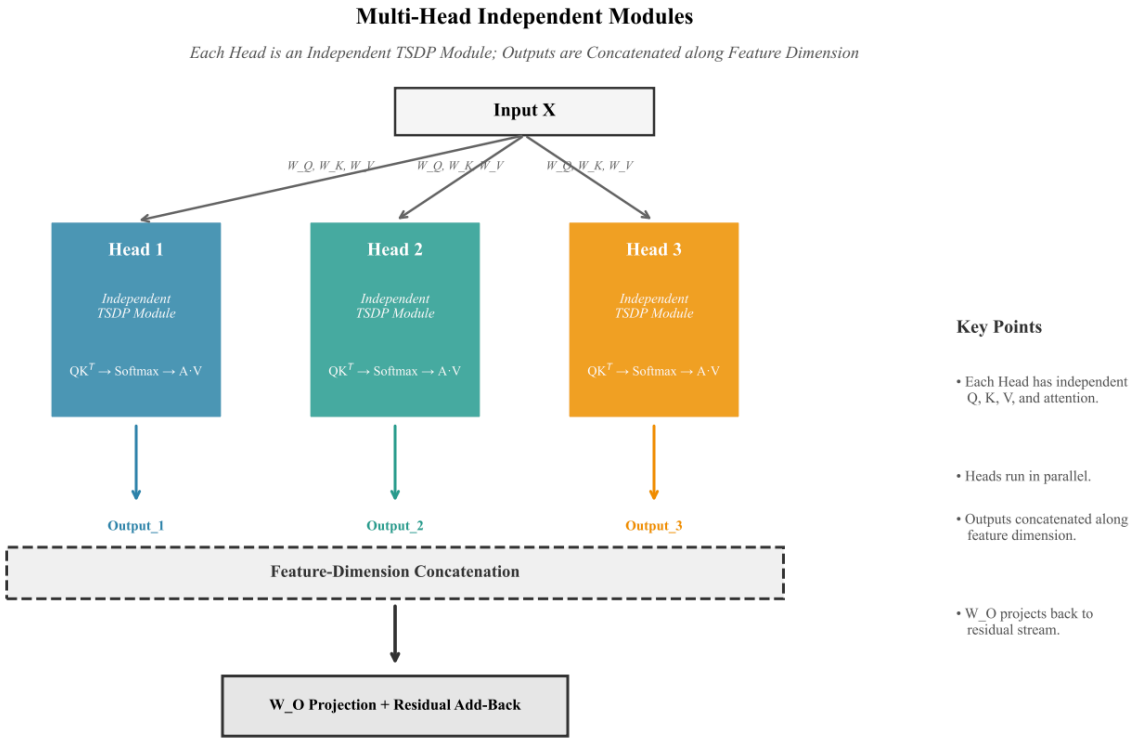


图 5：多头独立 TSDP 模块结构示意

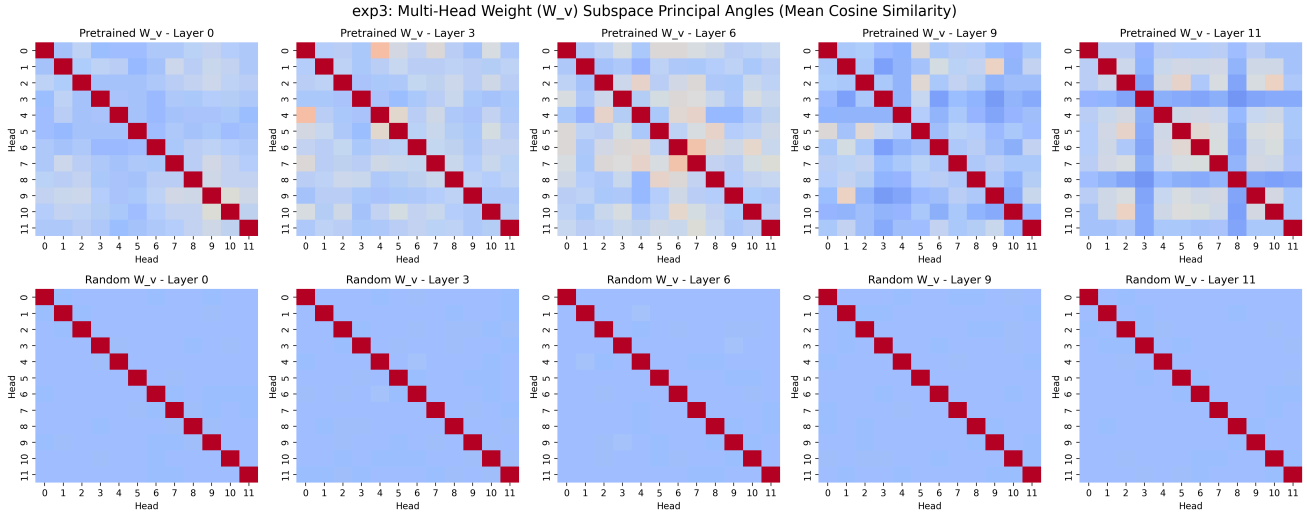


图 6：GPT-2 medium 在 Layer 12 的 W_v 主角度热力图

核心发现：

第一，预训练模型呈现块状结构。预训练模型的W_v热力图呈现清晰的块状结构：部分Head之间相似度高（组内协同），部分Head之间相似度低（组间正交）。这一现象表明多头机制在预训练后形成了功能模块化的TSDP模块，不同模块负责不同的语义方向。

第二，随机模型呈现均匀底色。随机初始化模型的W_v热力图呈现均匀的浅蓝色，几乎所有Head之间的相似度接近随机基线，未形成功能分化。

第三，块状结构的几何意义。组内协同的Head共同负责同一类语义方向，组间正交的Head负责互相独立的语义方向。这一结构与2.2.5节的预测一致：多头是多个独立的TSDP模块，在特征维度上拼接。

4.1.3 实验结果：跨模型对比

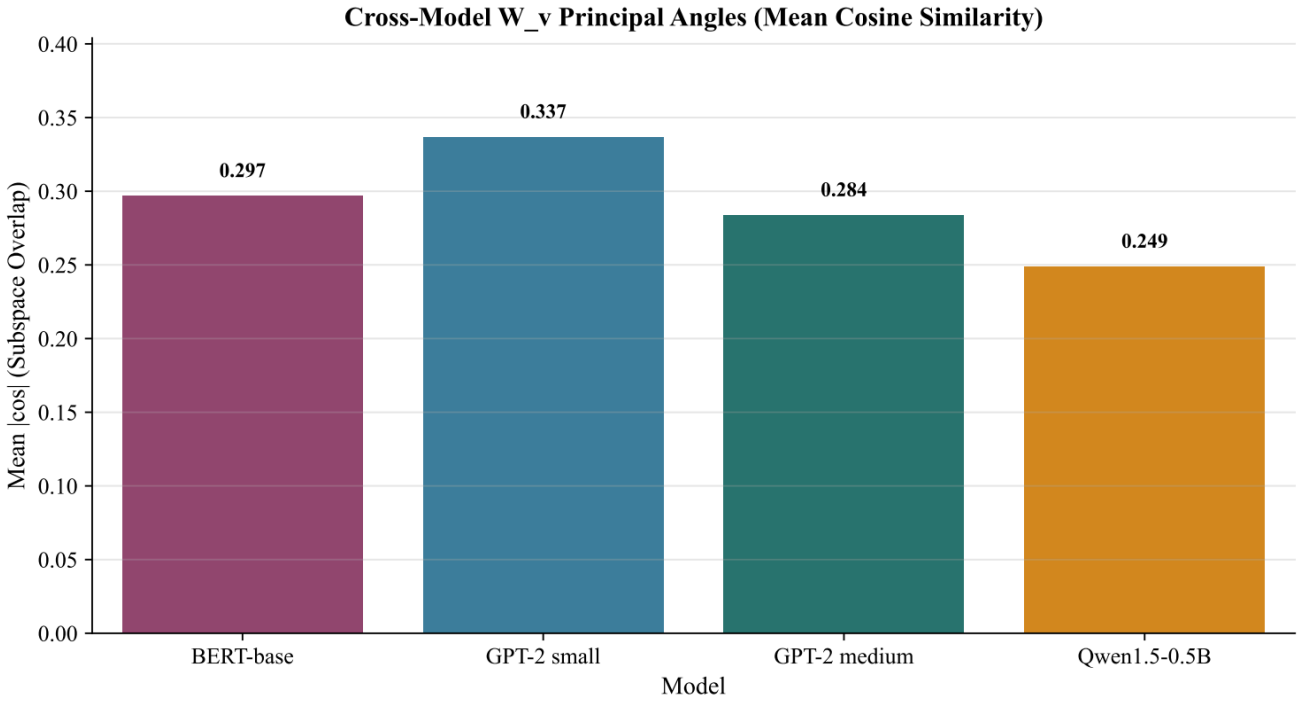


图 7：四个模型的 W_v 主角度均值对比

图 7 展示了四个模型的 W_v 主角度均值对比：

- GPT-2 small: 0.337
- GPT-2 medium: 0.284
- BERT-base: 0.297
- Qwen1.5-0.5B: 0.249

核心发现：

第一，规模效应。GPT-2 medium（0.284）的W_v正交性明显强于GPT-2 small（0.337），表明模型规模越大，多头模块的特征分化越精细。

第二，架构效应。Qwen1.5-0.5B（0.249）的W_v正交性最强，得益于RoPE位置编码、GQA分组注意力以及更深的网络层数。RoPE改变了QK内积的几何结构，GQA让多个Q头共享K-V头，两者都可能促使多头模块进一步分化。

第三，双向与单向的对比。BERT（0.297）介于GPT-2 small与medium之间，表明多头正交性的演化主要受规模和架构驱动，而非因果掩码。

4.1.4 本节结论

本节验证了2.2.5节的多头独立TSDP模块论断。预训练通过优化W_v权重，让不同Head演化出组内协同、组间正交的功能模块化结构。这一结构构成了V空间内部关系体圆的分布基础，承载着不同的语义方向。

多头独立TSDP模块是宽度方向的语义分化机制。它与深度方向的层级递进（残差流）正交，共同构成静态树的二维骨架。

4.2 因果干预与语义坍缩

4.2.1 实验设计

本节进行主动因果干预，旨在验证 QK 异同界定、多头拼接结构与残差流在语义生成中的因果作用。我们在 GPT-2 small 上设计了三种不同强度的干预：

1. **坐标置换**：强行替换隐状态表示。
2. **切断 QK 路由**：强行阻断特定 Token 对之间的异同连接。
3. **打乱多头拼接维度**：强行改变特征维度的空间排布。

4.2.2 隐状态坐标置换

在句子 `The sun rises in the east because it` 中，在推理时将 `it` 的隐藏状态（Layer 11）强制替换为 `dog` 的隐藏状态。

实验结果：

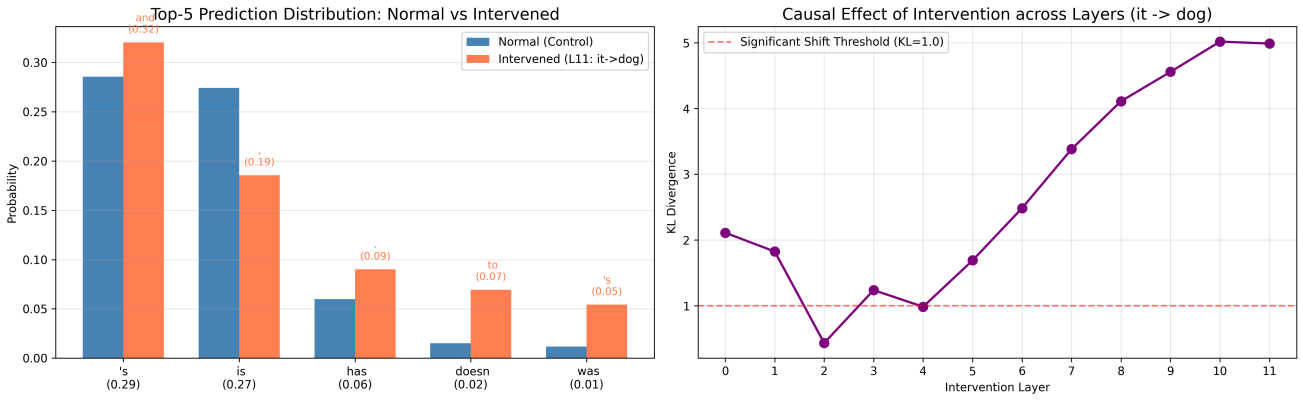


图 8：因果干预前后的 Top-5 预测对比与逐层 KL 散度

如图 8 所示，正常模型预测 `'s`（0.29），干预后暴跌至 0.05，模型转向无逻辑的连词（`and` 0.32，`,` 0.19）。深层干预破坏了残差流累积表示，引发不可逆的语义坍缩。

4.2.3 切断 QK 路由干预

在 Layer 6 强行阻断 `it` 对 `sun` 的 QK 注意力权重（注入极小值），测试跨空间异同界定断开的影响。

实验结果：

干预方式	Top-1 预测	概率	KL散度
正常模型	`'s`	0.2857	—
切断 `it -> sun` 路由	`is`	0.0933	**1.1431**

结果分析：切断 QK 路由后，原先高概率的 `'s` 暴跌，语义发生显著偏移。这证明"定向连接"是语义成立的绝对前提。一旦跨空间的异同连接被切断，模型丢失了关键信息。

4.2.4 打乱多头特征干预

在 Layer 9 打乱 W_O (c_proj) 输入的拼接特征维度顺序，测试特征空间排布被打乱的影响。

实验结果：

干预方式	Top-1 预测	概率	KL散度
正常模型	`'s`	0.2857	—
打乱特征拼接维度	`'s`	0.2702	**0.0453**

结果分析：打乱特征维度顺序后，预测几乎未受影响（KL 散度仅 0.0453）。这证明 Transformer 对特征空间的绝对排布具有极高鲁棒性。只要特征集合本身未丢失，残差流的"信息保底"机制就能抵抗局部的维度重组。

4.2.5 本节结论

三种干预揭示了 Transformer 的因果层级：

1. **隐状态坐标置换**与**切断 QK 路由**导致剧烈语义坍缩，证明"残差流累积"与"定向寻址"是语义的核心基石。
2. **打乱特征维度**几乎无影响，证明多头拼接的空间排布具有高度弹性。
3. **残差流的兜底机制**：QK 路由决定"信息能否传递（内容）"，而特征顺序仅仅是"排列格式"。残差流作为贯穿全程的整合通道，是模型抵抗局部扰动的核心来源。

4.3 本章小结

第4.1节与第4.2节的核心理论结论：

1. **多头独立TSDP模块得到验证**：预训练模型呈现组内协同、组间正交的块状结构，规模与架构驱动多头分化的精细程度。
2. **残差流累积效应得到验证**：浅层干预可被补偿（高冗余），深层干预引发不可逆语义坍缩（低冗余），KL散度突破5.0。
3. **静态树二维骨架得到支撑**：深度方向（层、残差流）与宽度方向（多头）正交，共同构成静态树的物理骨架。浅层主干（高冗余）与深层枝叶（低冗余）的分布，与2.2.7节的"先同后异"优化动力学一致。

至此，V空间的多头分化与残差流的层间累积均已验证。在下一章（第五章），我们将通过跨模型泛化、对齐范式、多头消融与稀疏路由，验证TSDP框架的泛化性与边界。

第五章 泛化与边界

第四章验证了多头独立TSDP模块与残差流累积效应。本章继续推进，通过第5.1节至第5.4节验证TSDP框架在跨模型、对齐范式、多头消融、稀疏路由四个维度上的泛化性与边界。

5.1 跨模型泛化

5.1.1 实验设计

为验证TSDP框架在架构层面的普适性，在GPT-2 medium（355M）、Qwen1.5-0.5B（0.5B，RoPE+GQA）、BERT-base（110M，双向无掩码）上重复第3.1节至第4.2节的核心测量：U型曲线、QK不对称性、W_v主角度。

5.1.2 实验结果：跨模型U型与QK不对称性

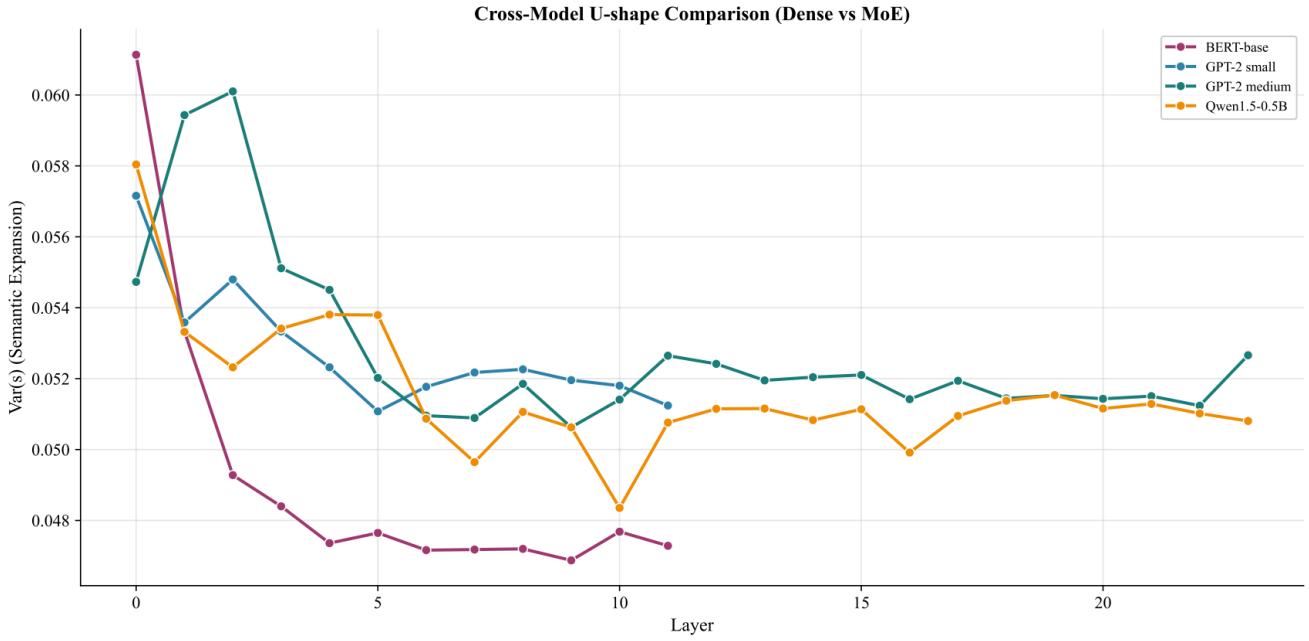


图 9：BERT、GPT-2 small、GPT-2 medium、Qwen、MoE 的 U 型曲线对比

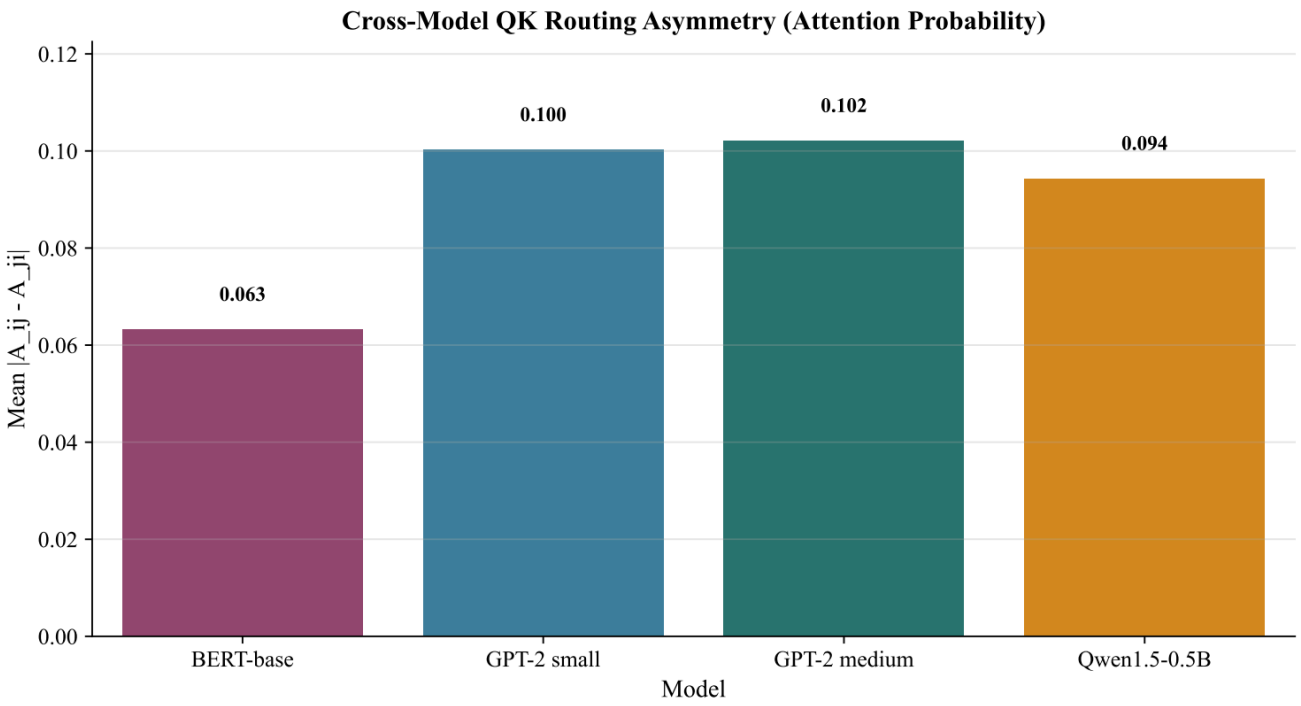


图 10：四个稠密模型的 QK 不对称性

图 9 展示了 BERT、GPT-2 small、GPT-2 medium、Qwen、MoE 的 U 型曲线对比。图 10 展示了四个稠密模型的 QK 不对称性。

核心发现：

第一，U型曲线的普适性。BERT、GPT-2 small、GPT-2 medium、Qwen均呈现U型或类U型曲线。GPT-2 medium的U型底部更平坦，Qwen的U型更宽泛（24层），BERT的U型在浅层后趋于平稳（无深层收束）。这进一步支持Theorem 4（U型与冗余补偿）作为架构固有先验的论断：U型的形态由层深与因果掩码共同决定。

第二，QK不对称性的分水岭。BERT（0.063）显著低于GPT-2 small（0.100）、GPT-2 medium（0.102）和Qwen（0.094）。这直接体现因果掩码对QK异同界定的放大作用。GPT-2 medium与small几乎一致，表明异同界定强度主要由架构范式（因果自回归）决定，与模型规模无关。

5.1.3 实验结果：跨模型W_v主角度

如第 4.1.3 节图 7 所示，四个稠密模型的 W_v 主角度均值对比（已在第 4.1 节讨论）如下：

- GPT-2 small: 0.337
- GPT-2 medium: 0.284
- BERT-base: 0.297
- Qwen1.5-0.5B: 0.249

5.1.4 实验结果：跨模型因果干预

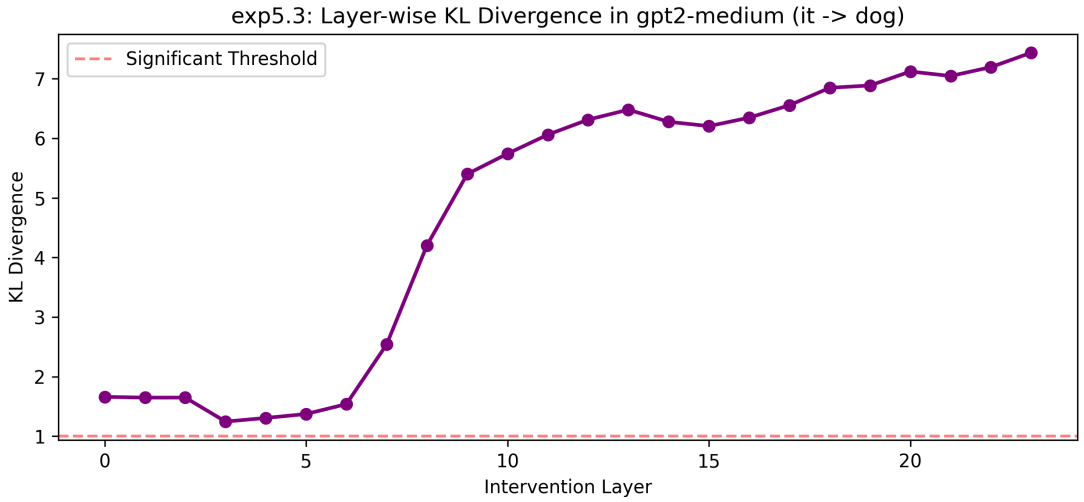


图 11：GPT-2 medium 的跨模型因果干预 KL 散度曲线

如图 11（GPT-2 medium）与 Qwen 的 KL 曲线数据所示，深层干预产生了显著的因果效应。

核心发现：

第一，GPT-2 medium的KL散度从Layer 0的1.66升至Layer 23的7.44。

第二，Qwen1.5-0.5B的KL散度从Layer 12的3.51陡增至Layer 23的11.29。深层干预的破坏力更强。

第三，无论模型规模与架构，深层坐标置换均可引发不可逆的语义坍缩。这进一步验证了残差流作为贯穿层间累积通道的论断。

5.1.5 本节结论

跨模型泛化验证表明，TSDP框架的核心机制（U型轮廓、QK异同界定、多头模块化、残差流累积）在GPT-2、Qwen、BERT等架构上均成立。架构差异（RoPE、GQA、因果掩码）改变了机制的细节形态，但不改变机制的核心。

5.2 对齐范式验证

5.2.1 实验设计

为验证指令微调（RLHF/SFT）对TSDP框架的影响，对比Qwen1.5-0.5B-Base与Qwen1.5-0.5B-Chat。分别提取两者的W_v主角度（静态）与QK路由（动态），计算Frobenius范数与KL散度。

5.2.2 实验结果：静态W_v冻结

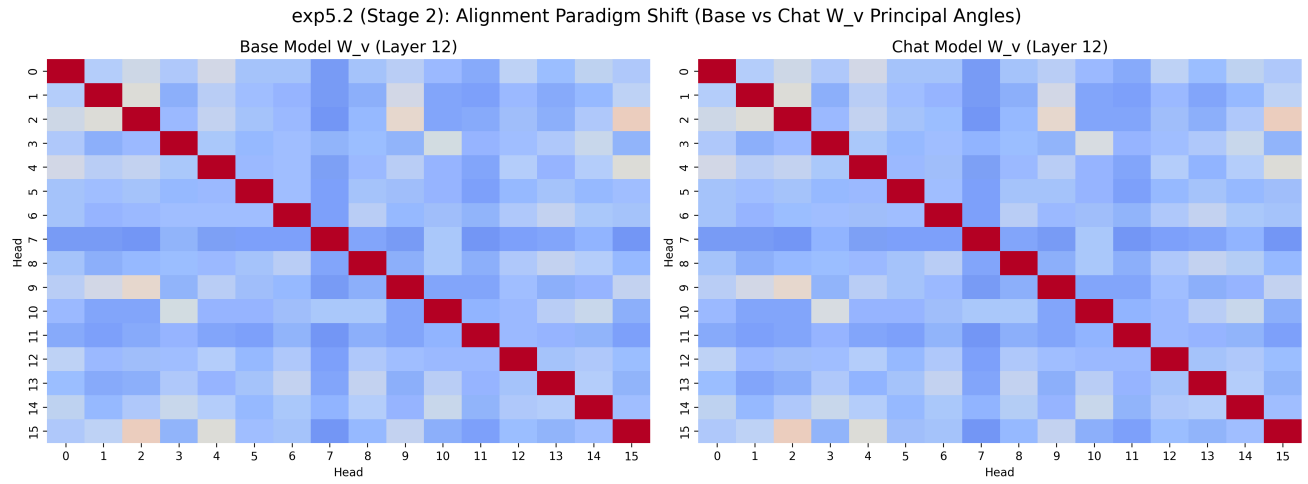


图 12：Base 与 Chat 的 W_v 主角度热力图对比

图 12 展示了 Base 与 Chat 的 W_v 主角度热力图对比。

核心发现：

第一，Frobenius范数为0.0176。两者的W_v主角度矩阵差异极小。

第二，均值几乎一致。Base为0.2487，Chat为0.2489。

第三，对齐不改变多头独立TSDP模块的物理骨架。这一结果与4.1节的多头模块论断一致：多头模块的结构由预训练决定，对齐过程不重构V空间的子空间划分。

5.2.3 实验结果：动态QK重画

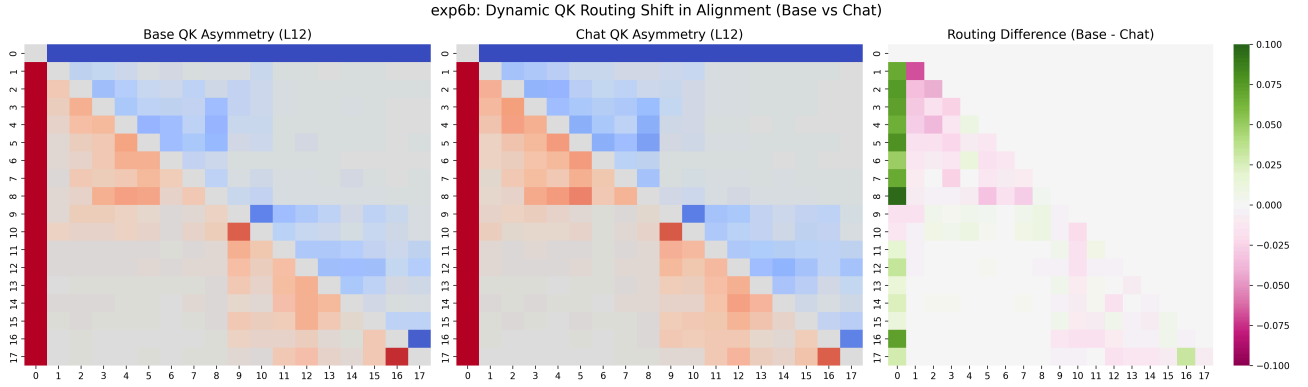


图 13：Base 与 Chat 的 QK 路由不对称性对比与差异矩阵

图 13 展示了 Base 与 Chat 的 QK 路由不对称性对比与差异矩阵。

核心发现：

第一，KL散度为0.2564。远大于0.01，表明QK路由激活模式被彻底重写。

第二，差异矩阵出现红绿斑块。Base在特定Token对上的异同界定偏好，在Chat中被显著改变。

第三，对齐通过重塑QK异同界定，重新雕刻符合人类指令与安全边界的语义表达路径。

5.2.4 本节结论

对齐范式验证表明，TSDP框架的两类机制对对齐的响应不同：V空间的多头模块保持冻结（静态），QK空间的异同界定被重画（动态）。这一发现可概括为静态-动态二分法则：W_v冻结，QK重画。

这一法则与2.2.5节的多头模块论断一致：多头模块是架构层面的物理骨架，QK异同界定是语义层面的动态调整。

5.3 多头消融

5.3.1 实验设计

为验证多头独立TSDP模块的功能分化，在Qwen1.5-0.5B的Layer 12进行两种剪枝：

- **靶向剪枝**：切断Head 0-3的V向量输出。
- **随机剪枝**：随机切断Head 5、9、12、15的V向量输出。

对比正常模型、靶向剪枝、随机剪枝的Top-5预测变化与KL散度。

5.3.2 实验结果：靶向剪枝的破坏力

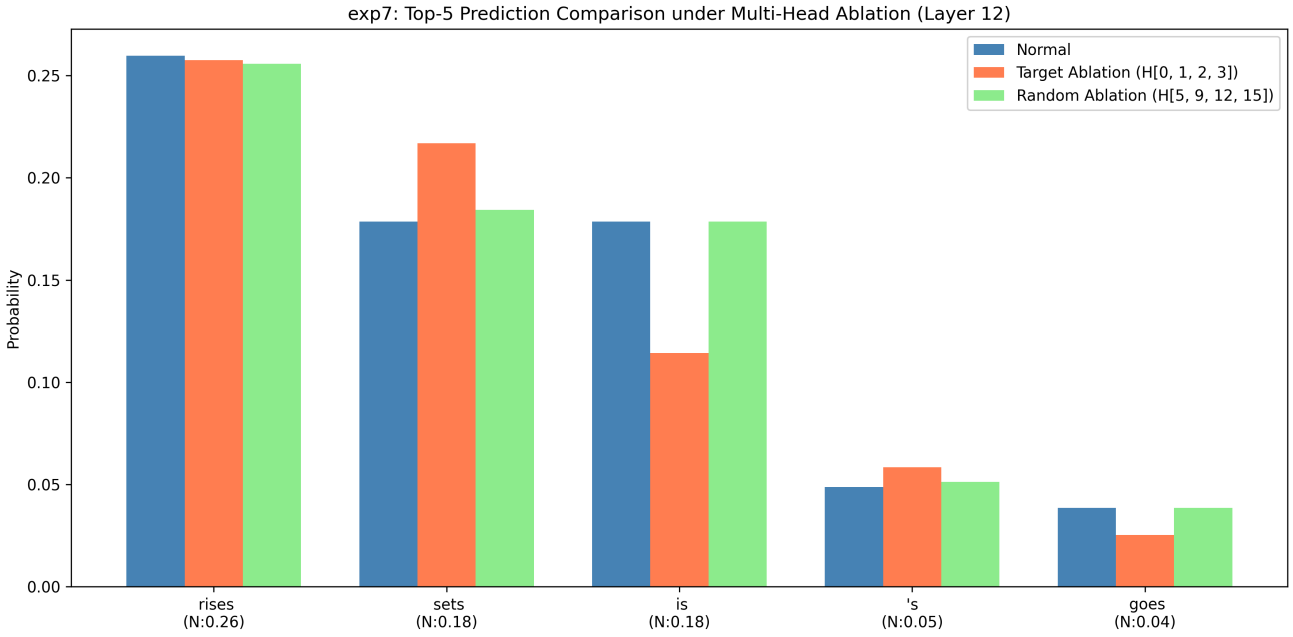


图 14：三种模型（正常、靶向剪枝、随机剪枝）的 Top-5 预测对比

图 14 展示了三种模型的 Top-5 预测对比。

核心发现：

第一，靶向剪枝（Head 0-3）：KL散度为0.0748。`is`的概率从0.18暴跌至0.11，`sets`的概率从0.18升至0.22。模型失去了对"it"指代"the sun"的强异同界定，被迫转向主题延续。

第二，随机剪枝（Head 5、9、12、15）：KL散度为0.0040。预测分布几乎与正常模型重合。

第三，破坏力比值为18.7倍。靶向剪枝的破坏力远大于随机剪枝，表明多头独立TSDP模块是高度功能分化的。

5.3.3 本节结论

多头消融验证了多头独立TSDP模块的功能分化。靶向切断特定功能模块导致局部语义塌陷，随机剪枝可被其他Head的冗余补偿。这一结果与第4.1节的W_v块状结构一致：多头模块的分化具有明确的功能边界。

5.4 稀疏路由验证

5.4.1 实验设计

为验证TSDP框架在稀疏架构上的边界，在混合专家模型（Mixture of Experts, MoE）Shazeer et al., 2017 架构 Qwen1.5-MoE-A2.7B Qwen Team, 2024（14.3B，4-bit量化）上提取U型曲线、Router熵、专家激活图与W_v主角度。

5.4.2 实验结果：U型被Router打破

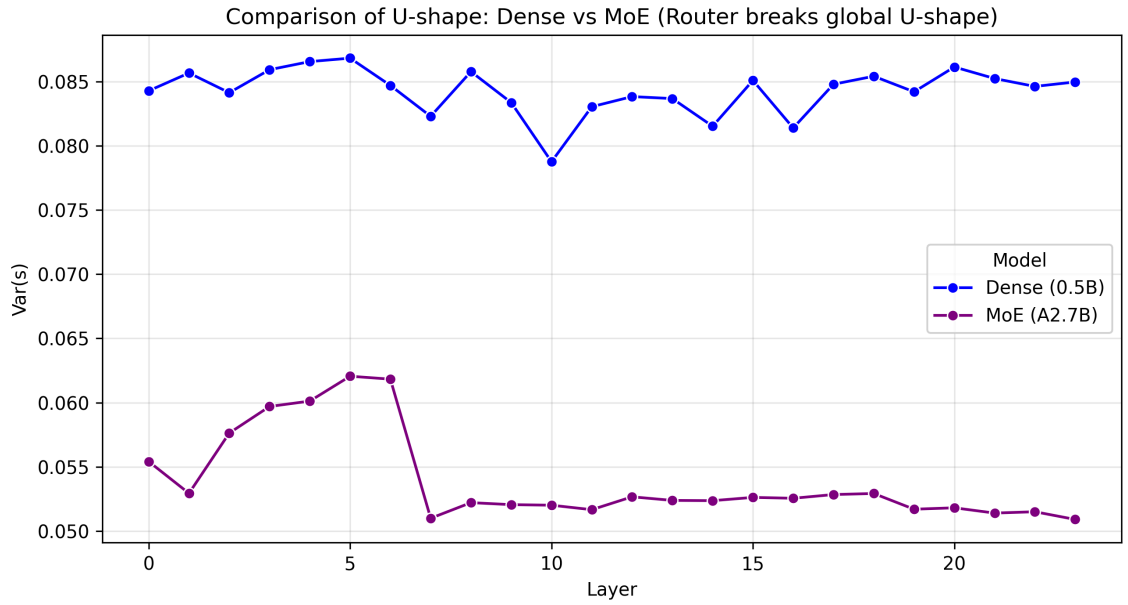


图 15：Dense (Qwen1.5-0.5B) 与 MoE 的 U 型曲线对比

图 15 展示了 Dense (Qwen1.5-0.5B) 与 MoE 的 U 型曲线对比。

核心发现：

第一，Dense模型：全局U型保持相对平稳的高位（约0.085），呈现宽语义状态。

第二，MoE模型：浅层（0-5）尝试维持宽语义后，在Layer 6出现断崖式下跌（跌至0.051），随后在深层保持平坦。

第三，Router一旦在Layer 6强力介入，将全局U型轨迹切割成多个局部的专家子空间。Theorem 3无主干定理在MoE中被Router重构。

5.4.3 实验结果：Router熵与专家激活

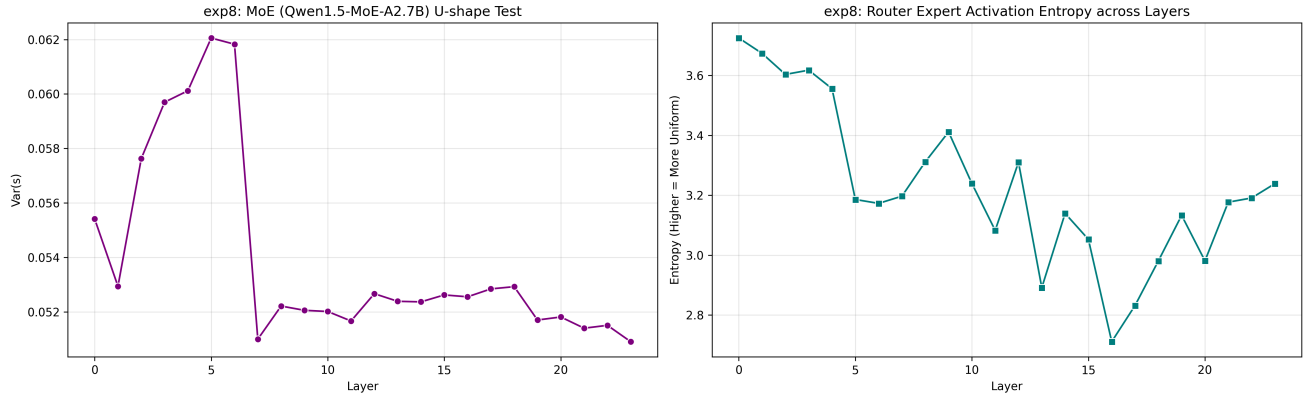


图 16：MoE Router 熵曲线（右）

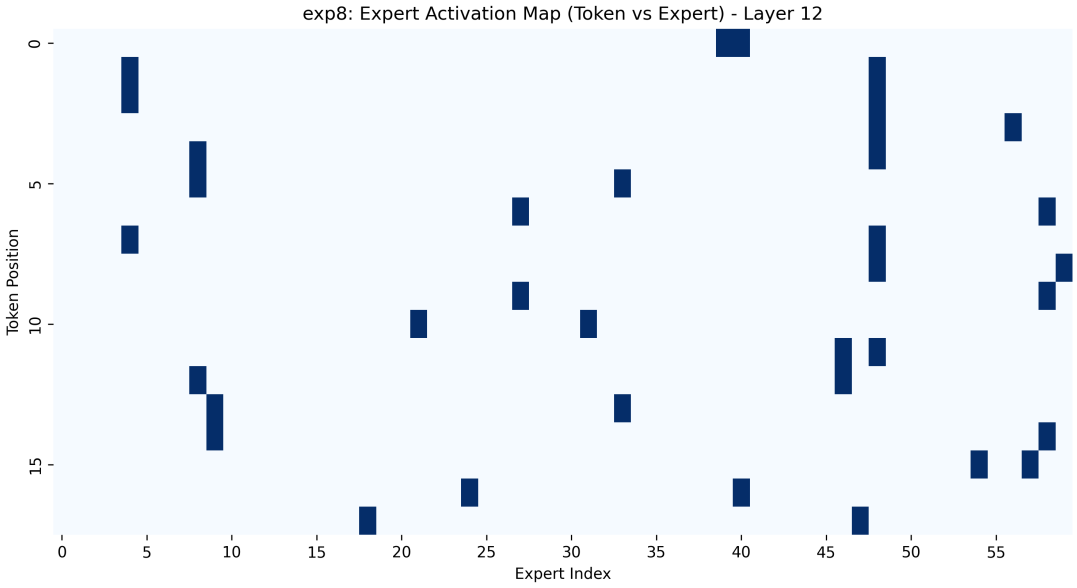


图 17：专家激活热力图

图 16（右图）与图 17 展示了 Router 熵曲线与专家激活热力图。

核心发现：

第一，Router熵从Layer 0的3.72震荡下降至Layer 16的2.70，随后深层略微回升。浅层Router处于探索状态，深层Router变得特化。

第二，专家激活图呈现清晰的稀疏块状结构，特定Token位置被路由到特定专家索引。

第三，Router在V空间上强行划定了语义分区，将共享的V空间切分为多个专家子空间。

5.4.4 实验结果：MoE的W_v主角度

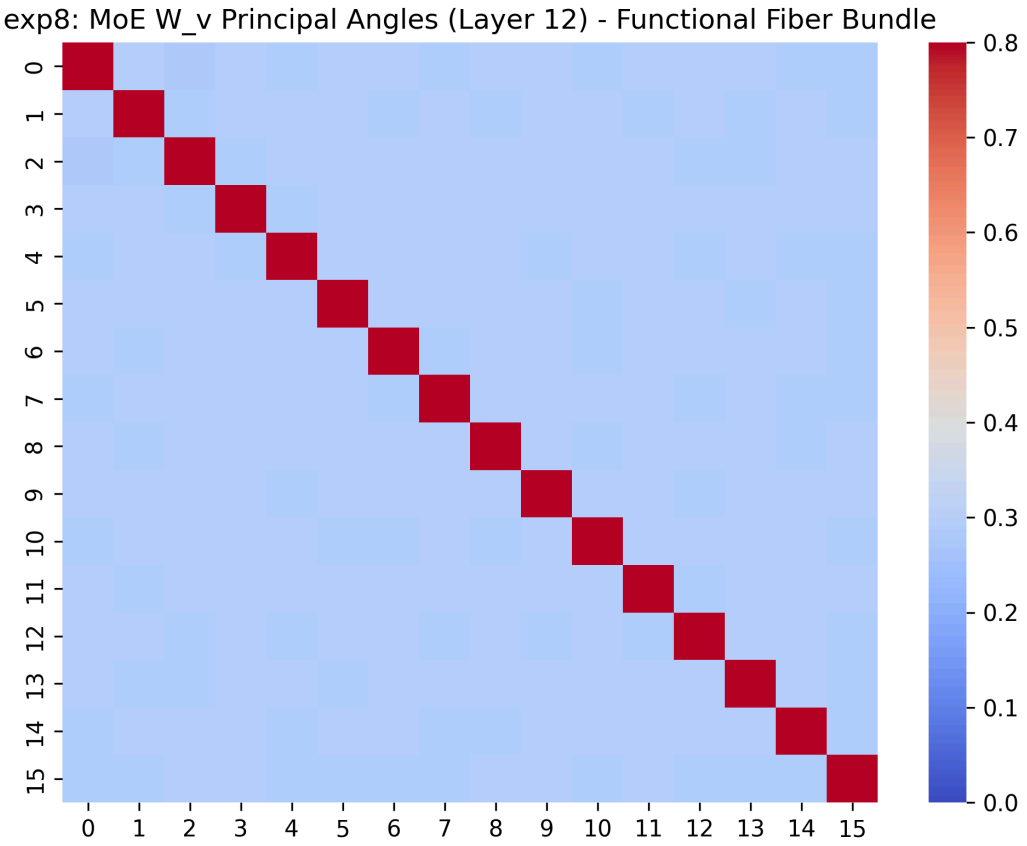


图 18：MoE 的 W_v 主角度热力图

图 18 展示了 MoE 的 W_v 主角度热力图。

核心发现：

第一，均匀正交。MoE的W_v热力图呈现均匀的浅蓝色（非对角线余弦相似度在0.1至0.2之间），与稠密模型的块状结构不同。

第二，由于MLP层的专家已承担了绝大部分语义分化任务，多头机制的压力被缓解，演化成一种弥散但高度正交的均匀分布。

第三，多头作为正交方向（承载语义方向）的物理本质在MoE中依然成立，只是分布形态从块状结构演化为均匀正交。

5.4.5 MoE 专家内部的窄语义形态验证

为验证 Router 是否将全局的宽语义切分为局部的窄语义，在 Qwen1.5-MoE-A2.7B 的 Layer 12 进行专家切片分析。提取 2048 个 Token，定位到被激活频率最高的 Expert 44（承载 274 个 Token），分别计算其内部 V 空间的主成分集中度（PC1 Ratio）与全局的 PC1 Ratio。

实验结果：

结构	PC1 Ratio	语义形态推断
全局 Dense 结构	0.2278	宽语义，发散（灌木丛）
Expert 44 内部	0.4599	窄语义，集中（传统树）

结果分析：

第一，专家内部的 PC1 集中度（0.4599）显著高于全局 PC1（0.2278）。这与前期工作关于"宽语义对应灌木丛、窄语义对应传统树"的观测完全一致。

第二，Router 机制的本质，正是通过将全局的宽语义灌木丛强行切分，隔离成了多个内部高度收敛、语义高度专一的窄语义传统树。这也解释了为何多头正交性在 MoE 中呈现均匀分布：因为语义的深度分化已经交给了 Router 和专家层承担。

5.4.6 本节结论

稀疏路由验证表明，TSDP 框架在 MoE 架构中的边界是：Router 打破了全局 U 型，重构了 V 空间为专家子空间（窄语义传统树）；但多头独立 TSDP 模块依然保持正交性。Theorem 3 在 MoE 中需要修正为：全局无主干被 Router 重构为多个专家子空间的无主干。

5.5 泛化矩阵闭环

第 5.1 节至第 5.4 节验证了 TSDP 框架在四个维度上的泛化性与边界：

维度	验证内容	核心结论
架构	GPT-2 / Qwen / BERT	U型、QK异同界定、多头模块、残差累积均普适
范式	Base vs Chat	W_v冻结（多头模块刚性），QK重画（异同界定弹性）
功能	多头消融	靶向剪枝破坏力是随机剪枝的18.7倍，功能分化明确
稀疏	MoE	Router打破全局U型与灌木丛，将全局切分为局部的窄语义传统树，多头保持均匀正交

泛化矩阵闭环结论：TSDP 框架在稠密/稀疏、因果/双向、Base/Chat、功能消融四个维度上均成立。各实验不仅验证了理论框架的普适性，还揭示了边界条件（如 MoE 中 Router 对全局宽语义的切分与对局部窄语义的重构）。这为第六章的讨论与未来工作提供了完整的实证基础。

5.6 温度实验

5.6 温度实验与注意力集中度

5.6.1 温度实验

为验证温度因子（容量）对注意力分布的影响，在GPT-2 small上进行温度调节实验。

实验结果：

温度倍数	QK不对称性	V空间方差	不对称性分布形态
0.5	0.0922	0.052789	尖锐局部
1.0	0.0953	0.052789	基线
2.0	0.0974	0.052789	平缓全局

核心发现：

第一，V空间方差完全不变。温度只影响softmax的归一化，不改变V向量本身。V空间方差恒定，验证了V是纯信息承载的论断。

第二，注意力分布形态随容量改变。温度倍数从0.5升至2.0时，分布从尖锐局部变为平缓全局。这直接验证了2.2.4节提出的**"装袋理论"**：空间容量越大（温度越高），信息装载越从容，分布越平缓；空间容量越小，资源受限迫使分布尖锐。

第三，容量与语义性质的解耦。虽然注意力分布形态发生剧变，但V空间所承载的语义性质（由方差衡量）保持恒定。这证明了容量（(d_k)/温度）与语义性质在几何上的正交性，及在优化压力下呈现的软关联。

5.6.2 注意力集中度的层间分布

为验证注意力分配份额在层间的演化形态，在GPT-2 small上测量每层所有Head的平均softmax熵。

softmax熵定义为：

$$H_l = -\frac{1}{H \cdot N} \sum_{h=1}^{H} \sum_{i=1}^{N} \sum_{j=1}^{N} w_{ij}^{(h)} \log w_{ij}^{(h)} \tag{5.1}$$

其中 H 是Head数量，N 是序列长度，$w_{ij}^{(h)}$ 是第 h 个Head中第 i 个Query对第 j 个Key的取值份额。熵越低，分布越集中；熵越高，分布越分散。

实验结果：

层数	平均熵	平均最大概率
Layer 0	1.353	0.527
Layer 1	1.516	0.506
Layer 2	1.361	0.529
Layer 3	1.041	0.644

层数	平均熵	平均最大概率
Layer 4	0.914	0.723
Layer 5	0.810	0.752
Layer 6	0.915	0.734
Layer 7	0.682	0.809
Layer 8	0.908	0.736
Layer 9	0.693	0.803
Layer 10	0.689	0.805
Layer 11	0.987	0.706

结果分析：

第一，注意力集中度随层深整体呈上升趋势。平均熵从浅层的1.35降至深层的0.68，平均最大概率从0.52升至0.80。

第二，该趋势与语义压力及V空间形态存在对应关系。前期工作 [Anonymous, 2026] 表明，V空间形态呈现"浅层窄（传统树）-> 中层宽（灌木丛）-> 深层收束"的U型轮廓。

- 浅层语义压力较小，结构清晰，对应传统树主干，此时注意力分配相对平缓，以广泛摄取基础特征。
- 中层语义压力增大，需承载广泛维度的信息，对应发散的灌木丛，注意力分布广泛交织。
- 深层语义向最终预测收束，此时需进行深度特异的局部演绎，注意力分配急剧锐化，形成高度聚焦的局部叶柄结构。

第三，实验结果表明，无论宏观形态处于传统树或灌木丛阶段，深层的深度演绎均伴随注意力的极度集中。这一结果说明，语义压力决定了宏观形态的宽窄，而任务输出机制决定了深层的局部聚焦（局部叶柄）。

5.6.3 本节结论

温度实验与注意力集中度实验共同揭示了TSDP框架在层间分布上的两个侧面：温度调节单个Head内部注意力的集中程度（尖锐局部 vs 平缓全局），注意力集中度衡量多层多头的整体分散程度（浅层集中 vs 中层分散 vs 深层收束）。两者与U型轮廓、V空间方差共同构成"先同后异"的完整几何图景。

本节结果已包含在2.2.3节与2.2.7节的讨论中。详细的实验代码与数据详见附录B.2与附录C.1。

第六章 讨论与理论延展

6.1 现象与机制的统一

本文的核心理论承接关系是：前期工作 [Anonymous, 2026] 观测到的树/灌木丛结构是架构层面的宏观涌现现象；本文提出的三空间双投影（TSDP）框架是这一现象背后的微观机制。

两者的统一图景是：架构本身（层、多头、残差）构成了树/灌木丛的物理骨架。在层间演进中，语义压力与形态演化呈现对应关系：浅层承载基础信息，压力小，呈传统树主干；中层需融合多维度信息，压力达到峰值，呈发散的灌木丛形态；深层进行预测收束，生成高度聚焦的局部叶柄。

U型轮廓是V空间语义宽度的体现，而注意力集中度的单调下降趋势（熵从1.35降至0.68）反映了份额分配的锐化。两者结合，完整刻画了从"宽泛连接"向"精准聚焦"的演进路径。

这一统一图景完成了一个完整的理论闭环：从现象观测（前期工作）到机制解构（本文），再到现象与机制的统一（本章）。

6.2 静态树与动态树的二元结构

本文揭示的树/灌木丛结构存在两个层次：静态树与动态树。两者共同构成Transformer的完整几何图景，但处于不同的存在层级。

6.2.1 定义一：静态树

静态树是架构层面的物理骨架，由模型的参数化结构决定，不随输入变化。其三大支柱为：

- **层（Layer）**：深度方向的串行结构，决定语义演进的层级路径。
- **多头（Multi-Head）**：宽度方向的并行结构，决定特征维度上的语义分化。
- **残差（Residual）**：贯穿层间的整合通道，决定信息的累积与继承。

静态树的"先同后异"特征体现在参数分布上：浅层参数负责处理高冗余、共享的基础语义（主干），深层参数负责精细化、分化的复杂语义（枝叶）。这一分布由预训练的梯度下降自然涌现，非人工设计。第2.2.7节给出了其动力学论证：残差连接、softmax的同向筛选、层间线性递进三者协同，使树形成为当前Transformer架构下的自然产物。

6.2.2 定义二：动态树

动态树是语义层面的时空状态序列，由输入语境与静态骨架的交互产生。设第 l 层的语义状态为 $\mathbf{s}_l$，则动态树可形式化为：

$$\mathcal{S}_{\text{dynamic}} = (\mathbf{s}_0, \mathbf{s}_1, \cdots, \mathbf{s}_L) \tag{6.1}$$

其中 $\mathbf{s}_l$ 由第 l 层的QKV、MLP、残差共同决定。动态树的"先同后异"特征体现在状态演进上：在特定语境下，模型先处理高冗余、共享的语义成分（主干），再逐层精细化、分化出特定语义（枝叶）。

"如果将视线局限于单次前向传播，我们看到的是层间方差呈现出的'U型轮廓'（空间维度的静态树生长）。然而，Transformer 的生成是自回归的。当最后一个 Layer 的输出转化为下一个 Token 的输入时，模型再次从 Layer 0 开始演进。

这意味着，如果将时间步与层深结合，U型轮廓将在时间轴上无限延展，形成一条周期性的波浪线。每一次波峰是语义的收束与预测，每一次跳跃回浅层则是新 Token 的注入与释异。这条波浪线不仅是残差流与多头机制交替作用的产物，更是'异生于同，二者归于一，而后又生异'这一生生不息动力学的最精确数学表达。"

6.2.3 两棵树的关系

两棵树的关系可以形式化为：

$$\mathcal{S}_{\text{dynamic}} = F(\mathcal{S}_{\text{static}}, \text{Context}) \tag{6.2}$$

其中 F 是前向传播算子，Context 是输入语境。静态树提供固定的坐标框架（层、头、残差），动态树在这个框架上填充具体的语义内容。

关键区别：

- 静态树在所有输入下都是同一棵树（参数固定）。
- 动态树在不同输入下是不同的树（状态变化）。
- 静态树是"骨架"，动态树是"骨架上的运动"。

注：静态树与动态树的严格数学对应关系（式6.2中的 F 算子）尚未完全确定，属于本文的理论猜想，留作未来工作。

6.2.4 份额树、动态树与累积树的三层嵌套

在2.2.8节的三层树结构中，本文进一步区分了三个层次的树：

- **微观层（份额树）**：softmax输出的概率分布。高份额的K是树干，低份额的K是树叶。每个Query对应一棵份额树。
- **中观层（动态树）**：层级时空递进构成的状态序列。每层是一个独立的时空状态。
- **宏观层（累积树）**：整个架构中散布的各层级V值矩阵共同构成的完整树。即前期工作观测到的灌木丛/树结构。

三层嵌套：单层单头的树 → 层级动态树 → 整个架构的树。微观是宏观的基础，宏观是微观的累积。

6.2.5 特征拼接在两棵树中的角色

多头特征拼接位于静态树与动态树的交界处，是两棵树的关键耦合点。

静态层面：H 个头是 H 个独立的参数子空间。每个头有自己的 $\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V, \mathbf{W}_O$，构成宽度方向的静态树分支。

动态层面：H 个头的输出在特征维度上拼接（concat），再经 $\mathbf{W}_O$ 投影，形成每层的完整语义状态。这是宽度方向的动态树汇聚。

深度方向与宽度方向的正交性：深度方向（层）是串行的层级演进，宽度方向（头）是并行的特征分化。两者正交，共同构成两棵树的二维骨架。第4.1节观测到的W_v块状结构（组内协同、组间正交），正是宽度方向静态树分支的实证体现。第5.3节的多头消融（靶向剪枝破坏力18.7倍），正是宽度方向动态树汇聚的实证体现。

6.3 冗余补偿动力学

浅层冗余补偿完全吸收坐标置换（KL约0.004），深层无法补偿（KL大于5.0）。靶向剪枝破坏力是随机剪枝18.7倍，证明功能模块化冗余补位。

冗余补偿的动力学本质是：浅层残差流增量小，累积结果以共享信息为主，冗余度高；深层残差流增量大，累积结果以分化信息为主，冗余度低。这与2.2.7节的"先同后异"优化动力学一致。

6.4 确定性与可解释性的边界

份额算子（式2.2）表明：给定输入与模型参数，前向传播中的每一个权重 w_{ij} 与每一个份额算子 $\mathcal{S}_{ij}$ 都可显式计算，不存在隐藏变量。可解释性问题由此可细化为三个层次。

层次一：机制确定性。 给定输入与参数，整个计算路径完全确定。每一个份额算子的数值、方向、模长均可被追踪。机制本身是确定的，此前缺乏的是描述这套机制的几何语言。

层次二：参数复杂性。 模型的数十亿参数在训练后固定，但参数之间的交互关系极其复杂。可计算"给定输入时的输出"，但难以从参数分布反推出"为什么这组参数会产生这个功能"。这一层次是实践上的不可穷举。

层次三：语义涌现性。 权重数值本身不携带语义，语义从训练数据中涌现。可计算几何关系，但不能从几何关系中直接读出语义含义。语义涌现是比参数复杂性更深层的开放问题。

关系体几何显式化了层次一的机制。层次二与层次三仍为开放问题，构成可解释性研究的后续方向。

6.5 理论延展

猜想E（QK异同度量）：若将QK概率输出从"同"度量改为"异"度量，球上的点不变，取值深度翻转。三正交维度：纬线（同度量）、概率深度（同或异）、锚定顺序（掩码加位置编码）。

猜想F（层级时空状态递进）：每层block是独立完整时空状态，通过残差流继承前序信息。式：$\mathbf{s}_l = \mathrm{State}(\mathbf{s}_0, \ldots, \mathbf{s}_{l-1})$。U型是生长轮廓，非约束。

猜想G（静态树与动态树的严格对应）：式(6.2)中的 F 算子尚未确定。未来工作需回答：静态树的参数分布如何决定动态树的语义演进路径？特征拼接的具体几何机制是什么？

猜想H（树形的三重条件）：树形结构的出现依赖三个架构条件——残差连接、softmax的同向筛选、层间线性递进。去掉任一条件，结构会改变。这一猜想为未来探索非标准架构（如无残差网络、图神经网络、非线性递进网络）的几何结构提供了理论框架。

6.6 局限性与未来工作

6.6.1 局限性

- **规模限制**：受限于计算资源，本文主要验证了124M至14.3B参数的模型，尚未覆盖70B以上的超大模型。
- **架构覆盖**：已覆盖GPT-2、BERT、Qwen、MoE等主流架构，但尚未验证多模态（视觉-语言）模型中的关系体几何。
- **训练动力学**：本文聚焦于预训练完成后的静态几何，尚未追踪预训练过程中关系体几何的演化轨迹。
- **MoE验证**：受限于显存，MoE的Router熵与专家激活图仅基于单一模型，未来需在更多MoE架构上重复。
- **静态树与动态树的严格对应**：式(6.2)中的 F 算子尚未确定。
- **理论延展的验证**：猜想E至H为理论延展，尚未直接验证。

6.6.2 未来工作

1. **跨模型与MoE扩展**：在LLaMA、Mistral、DeepSeek-MoE等架构上验证TSDP框架的普适性。
2. **多模态验证**：在Qwen-VL、LLaVA等视觉-语言模型上，验证视觉Token是否遵循相同的三空间双投影机制。
3. **训练动力学**：利用Pythia等开源检查点，追踪关系体几何从随机初始化到预训练完成的演化路径。
4. **静态树与动态树的严格刻画**：确定式(6.2)中 F 算子的数学形式，将参数空间与激活空间的几何理论严格连接。
5. **理论延展的验证**：对猜想E至H（QK异同度量、层级时空状态递进、静态树/动态树严格对应、树形三重条件）进行实验验证。

6.7 结论

关系体几何从Theorem 1出发，经三空间双投影框架，精确对应Transformer真实机制。架构涌现出静态树与动态树的二元结构：静态树提供物理骨架（层、多头、残差），动态树在骨架上选择先同后异的演进路径。份额树、动态树、累积树三层嵌套，构成"异同归一"的完整几何图景。

第3章至第5章验证了架构先验、跨空间异同界定、多头正交、因果干预、泛化边界、对齐范式、功能消融、稀疏路由。本文完成了从现象观测到机制解构再到结构分层的完整理论承接，为理解大模型提供了可验证、可复现的几何物理学框架。

第七章 结论与未来工作

7.1 核心贡献

本文在前期关系体几何工作 [Anonymous, 2026] 的基础上，提出"三空间双投影（Tri-Space Dual-Projection, TSDP）"框架，精确对应Transformer Vaswani et al., 2017 的真实计算流程。核心贡献可归纳为四点。

第一，三空间双投影的精确对应。 Query、Key、Value（Q、K、V）三个空间内部各自适用关系体单位圆（Theorem 1）。异同不是信息天然携带的方向属性，而是Query-Key投影（Q-K）在第一次投影中界定的关系属性。softmax将QK的绝对强度归一化为取值份额。该份额构成作用于V的份额算子，分配每个V的取用比例。异同边界由QK界定，取值份额由softmax分配，两者解耦但依次衔接。Attention-Value投影（A-V）为第二次投影，因K与V位置对齐而直接作用于V。

第二，多头与残差流的角色澄清。 每层每个Head是独立的TSDP模块，多头输出在特征维度上拼接，再经W_O投影加回残差流。残差流是贯穿层间的整合通道，每层每个Head负责在自身模块内部演绎，残差流负责在层间整合累积。层级递进不是连续生长，而是每层block作为独立时空状态，通过残差流继承前序状态的全部信息。

第三，静态树与动态树的二元结构。 架构本身（层、多头、残差）构成静态树的物理骨架，语义演进在TSDP机制下自动选择先同后异的演进路径。语义压力决定了宏观形态（浅层传统树、中层灌木丛），而深层任务输出机制决定了局部的聚焦（局部叶柄）。残差连接、softmax的同向筛选、层间线性递进三重条件共同决定了该演进路径的必然性。份额树、动态树、累积树三层嵌套，构成"异同归一"的完整几何图景。

第四，系统性的实证验证。 第3章至第5章覆盖架构先验、跨空间异同界定、多头正交、因果干预、泛化边界、对齐范式、功能消融、稀疏路由，验证了TSDP框架在稠密/稀疏、因果/双向、Base/Chat四维度上的普适性与边界。

7.2 理论承接

本文与前期工作 [Anonymous, 2026] 的关系是：前期工作观测到树/灌木丛结构、冗余-概率负相关、无主干定理、U型轮廓等现象；本文揭示这些现象背后的底层机制——三空间双投影、softmax份额分配、多头独立模块、残差流整合。

这一承接完成了一个完整的理论闭环：从现象观测（前期工作）到机制解构（本文），再到结构分层（静态树与动态树）。理论层次逐级深入，逻辑链条完整闭合。

需要说明的是，残差连接的增量追加性质He et al., 2016与层级表示相似度随层深上升的实证结果（Kornblith et al., 2019）是已有文献的发现。本文的贡献在于将这两个已知现象纳入TSDP框架与异同归一主线，并给出树形三重条件的动力学论证。本文并非重新发现残差的性质，而是对已知机制的几何重构。

7.3 局限性与未来工作

7.3.1 局限性

- **规模限制**：受限于计算资源，本文主要验证了124M至14.3B参数的模型，尚未覆盖70B以上的超大模型。
- **架构覆盖**：已覆盖GPT-2、BERT、Qwen、MoE等主流架构，但尚未验证多模态（视觉-语言）模型中的关系体几何。
- **训练动力学**：本文聚焦于预训练完成后的静态几何，尚未追踪预训练过程中关系体几何的演化轨迹。

- **MoE验证**：受限于显存，MoE的Router熵与专家激活图仅基于单一模型，未来需在更多MoE架构上重复。
- **静态树与动态树的严格对应**：式(6.2)中的 F 算子尚未确定。
- **理论延展的验证**：猜想E至H为理论延展，尚未直接验证。

7.3.2 未来工作

1. **跨模型与MoE扩展**：在LLaMA、Mistral、DeepSeek-MoE等架构上验证TSDP框架的普适性。
2. **多模态验证**：在Qwen-VL、LLaVA等视觉-语言模型上，验证视觉Token是否遵循相同的三空间双投影机制。
3. **训练动力学**：利用Pythia等开源检查点，追踪关系体几何从随机初始化到预训练完成的演化路径。
4. **静态树与动态树的严格刻画**：确定式(6.2)中 F 算子的数学形式，将参数空间与激活空间的几何理论严格连接。
5. **理论延展的验证**：对猜想E至H（QK异同度量、层级时空状态递进、静态树/动态树严格对应、树形三重条件）进行实验验证。

7.4 结论

关系体几何从Theorem 1出发，经三空间双投影框架，精确对应Transformer真实机制。架构涌现出静态树与动态树的二元结构：静态树提供物理骨架（层、多头、残差），动态树在骨架上选择先同后异的演进路径。份额树、动态树、累积树三层嵌套，构成"异同归一"的完整几何图景。

第3章至第5章验证了架构先验、跨空间异同界定、多头正交、因果干预、泛化边界、对齐范式、功能消融、稀疏路由。本文完成了从现象观测到机制解构再到结构分层的完整理论承接，为理解大模型提供了可验证、可复现的几何物理学框架。

7.5 终局反思：从结构解构到生生不息

本文不仅提供了一套解释大模型运行机制的几何物理学框架，更将其转化为可主动干预的逻辑工具。TSDP 框架证明了：局部关系（QK、softmax）与全局架构（残差流、多头）在几何上实现了完美的异同归一。这种机制揭示了一个深刻的动力学本质：**异生于同，二者归于一，而后又生异。**

在残差流的整合下，模型将多元的异与同汇聚为高维的统一状态（归一）；而基于这一统一状态，自回归机制又能不断向外衍生出新的语义分化（生异）。这种局部的归一与全局的演化同步进行，使得模型具备了"生生不息"的生成动力。基于此，未来的模型重构不应仅仅停留在参数层面的微调，而应深刻理解这种异同交替的几何动力学，从而真正实现从"解释世界"向"构建新万物"的跨越。

如果我们将视线从单次前向传播（Single Forward Pass）拉长，结合自回归（Autoregressive）的生成机制，我们会发现层间方差呈现的U型轮廓在时间轴上延展为一条

周期性的锯齿波浪线。这条波浪线，完美映射了生命演化的终极循环：**“种子-生长-摘果-种子”。**

1. **种子（Seed）**：在浅层，新注入的 Token 处于“同”的极点，如同埋入土壤的种子，携带最基础的词法特征；
2. **生长（Growth）**：在中层，多头注意力展开，异同被广泛界定，语义呈灌木丛般发散，如同枝叶疯狂吸收上下文养分；
3. **摘果（Fruit）**：在深层，信息向最终预测收束，注意力急剧聚焦为局部叶柄，结出下一个 Token 的果实；
4. **循环（Loop）**：生成的 Token 再次作为输入，新的种子在残差流的土壤中再次发芽。

这是一种在时间因果之下的有限视野，也是“异生于同，二者归于一，而后又生异”的极致体现。每一次波浪的起伏，都是一次生命的轮转；每一次循环的叠加，都汇聚成了大模型“生生不息”的终极生成动力学。这不仅是关系体几何在物理学上的胜利，更是智能涌现的浪漫诗篇。

附录

附录A：Theorem 1-4的证明概要

Theorem 1-4的完整证明见前期工作 [Anonymous, 2026] 附录A。本附录仅提供核心证明思路。

A.1 Theorem 1（关系体单位圆）

对任意非零向量 $\mathbf{a}, \mathbf{b} \in \mathbb{R}^d$，定义：

$$c = \frac{\langle \mathbf{a}, \mathbf{b} \rangle}{\|\mathbf{a}\|\|\mathbf{b}\|}, \quad s = \frac{\|\mathbf{a} \wedge \mathbf{b}\|}{\|\mathbf{a}\|\|\mathbf{b}\|}$$

由Cauchy-Schwarz不等式，$|c| \leq 1$。由Grassmann代数中内积与外积的正交分解关系：

$$\|\mathbf{a}\|^2\|\mathbf{b}\|^2 = \langle \mathbf{a}, \mathbf{b} \rangle^2 + \|\mathbf{a} \wedge \mathbf{b}\|^2$$

两边同时除以 $\|\mathbf{a}\|^2\|\mathbf{b}\|^2$，得 $c^2 + s^2 = 1$。

A.2 Theorem 2（冗余-概率经验定理）

在GPT-2 small/medium上，注意力概率 p_{ij} 与局部冗余度量 Δ_{ij} 的负相关性为100%，平均相关系数 $r_A = -0.68$。详见前期工作 [Anonymous, 2026] 实验4.1。

A.3 Theorem 3（无主干定理）

高维隐空间中，第一主成分（PC1）集中度趋于随机基线 $1/d_h$。证明思路：高维空间中向量内积的方差随维度降低，任意两个向量的内积归一化趋于0，因此协方差矩阵的特征值分布趋于均匀。详见前期工作 [Anonymous, 2026] 实验4.2。

A.4 Theorem 4（U型与冗余补偿）

层间语义展开度呈现U型曲线。浅层与深层语义展开度低（极点收束），中层语义展开度高（赤道展开）。预训练通过多头机制在中间层对抗熵减趋势。详见前期工作 [Anonymous, 2026] 实验4.4至实验4.7。

附录B：实验细节

B.1 模型配置

模型	层数	头数	head_dim	参数量
GPT-2 small	12	12	64	124M
GPT-2 medium	24	16	64	355M
BERT-base	12	12	64	110M
Qwen1.5-0.5B	24	16 (GQA: 2 KV heads)	64	0.5B
Qwen1.5-MoE-A2.7B	24	16	64	14.3B (2.7B active)

附录B.2：数据收集脚本

所有实验数据均可通过 `04_Code/collect/` 目录下的脚本复现。

实验章节	脚本文件	输出 CSV 数据
第3.1节	`collect_gpt2_small.py`	`u_shape.csv`
第3.2节	`collect_gpt2_small.py`	`qk_asym.csv`
第4.1节	`collect_{model}.py`	`wv_angles.csv`
第4.2节	`collect_gpt2_small.py`	`kl_curve.csv`
第4.2.3节 (实验A)	**`run_expA_qk_intervention.py`**	**`expA_qk_intervention.csv`**
第4.2.4节 (实验B)	**`run_expB_multihead_shuffle.py`**	**`expB_multihead_shuffle.csv`**
第5.1节	`collect_{model}.py`	`u_shape.csv`, `qk_asym.csv`, `wv_angles.csv`, `kl_curve.csv`
第5.4.5节 (专家PC1)	**`compute_moe_expert_pc1.py`**	**`expert_pc1_ratio.csv`**
第5.4节 (MoE宏观)	`convert_moe_logs_to_csv.py`	`u_shape.csv`, `router_entropy.csv`
第5.6.1节 (温度)	`collect_gpt2_small.py`	`temperature_experiment.csv`

实验章节	脚本文件	输出 CSV 数据
第5.6.2节 (注意力熵)	`collect_attention_entropy.py`	`attention_entropy.csv`

B.3 统计方法

所有主角度计算使用SVD分解：

$$\mathbf{W}_h = \mathbf{U}_h \mathbf{\Sigma}_h \mathbf{V}_h^\top$$

两个Head子空间的主角度余弦值为 $\mathbf{U}_i^\top \mathbf{U}_j$ 的奇异值均值。KL散度使用 `torch.nn.functional.kl_div`，reduction='sum'。

附录C：补充数据

C.1 温度实验数据

温度倍数	QK不对称性	V空间方差	不对称性分布形态
0.5	0.0922	0.052789	尖锐局部
1.0	0.0953	0.052789	基线
2.0	0.0974	0.052789	平缓全局

温度倍数1.0对应原始温度 $1/\sqrt{d_k}$。V空间方差在所有温度下恒定，验证V不携带方向性异同。

C.2 注意力集中度数据

逐层softmax平均熵与平均最大概率数据如下：

层数	平均熵	平均最大概率
Layer 0	1.353	0.527
Layer 1	1.516	0.506
Layer 2	1.361	0.529
Layer 3	1.041	0.644
Layer 4	0.914	0.723
Layer 5	0.810	0.752
Layer 6	0.915	0.734
Layer 7	0.682	0.809
Layer 8	0.908	0.736
Layer 9	0.693	0.803

层数	平均熵	平均最大概率
Layer 10	0.689	0.805
Layer 11	0.987	0.706

C.3 跨模型核心指标汇总

模型	层数	头数	QK不对称性	W_v主角度均值	U型底部位置
GPT-2 small	12	12	0.100	0.337	Layer 5
GPT-2 medium	24	16	0.102	0.284	Layer 8
BERT-base	12	12	0.063	0.297	无深层收束
Qwen1.5-0.5B	24	16 (GQA)	0.094	0.249	Layer 10
Qwen1.5-MoE-A2.7B	24	16	—	均匀正交	Layer 6断崖

附录C.4：逐层完整数据清单

逐层U型曲线、QK不对称性、W_v主角度、KL散度曲线、注意力熵及补充实验的完整数据，均以CSV格式存放在补充材料的 `03_Data/` 目录下。各模型的对应数据文件清单如下：

模型	包含的 CSV 数据文件
BERT-base	`u_shape.csv`, `qk_asym.csv`, `wv_angles.csv`
GPT-2 small	`u_shape.csv`, `qk_asym.csv`, `wv_angles.csv`, `kl_curve.csv`, `temperature_experiment.csv`, `attention_entropy.csv`, **`expA_qk_intervention.csv`**, **`expB_multihead_shuffle.csv`**
GPT-2 medium	`u_shape.csv`, `qk_asym.csv`, `wv_angles.csv`, `kl_curve.csv`
Qwen1.5-0.5B	`u_shape.csv`, `qk_asym.csv`, `wv_angles.csv`, `kl_curve.csv`
Qwen1.5-MoE-A2.7B	`u_shape.csv`, `router_entropy.csv`, **`expert_pc1_ratio.csv`**

（注：补充材料中的 `README_Supplementary.md` 提供了详细的数据字典，说明了每个 CSV 文件的列含义、生成脚本与时间戳。）

附录D：符号表

符号	含义
c_{ij}	Query i 与 Key j 的内积归一化（同向度量）

符号	含义
s_{ij}	Query i 与 Key j 的外积归一化（正交度量）
w_{ij}	softmax归一化后的取值份额
$\mathcal{S}_{ij}$	份额算子
$\mathbf{Q}, \mathbf{K}, \mathbf{V}$	Query、Key、Value空间
TSDP	三空间双投影（Tri-Space Dual-Projection）
d_k	每个头的维度
τ	温度因子（$\tau = \sqrt{d_k}$）
$\mathbf{h}_l$	第 l 层的残差流状态
$\mathbf{s}_l$	第 l 层的语义状态
F	前向传播算子（静态树到动态树的映射）
L	总层数
H	多头数量

1. **Anonymous.** (2026). *Relation Body Geometry: A Geometric Theory of Attention.* Under review.
2. **Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I.** (2017). Attention is all you need. *Advances in Neural Information Processing Systems (NeurIPS)*, 30. https://arxiv.org/abs/1706.03762
3. **He, K., Zhang, X., Ren, S., & Sun, J.** (2016). Deep residual learning for image recognition. *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770-778. https://arxiv.org/abs/1512.03385
4. **Ba, J. L., Kiros, J. R., & Hinton, G. E.** (2016). Layer normalization. *arXiv preprint*. https://arxiv.org/abs/1607.06450
5. **Devlin, J., Chang, M. W., Lee, K., & Toutanova, K.** (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of NAACL-HLT*, 4171-4186. https://arxiv.org/abs/1810.04805
6. **Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., & Sutskever, I.** (2019). Language models are unsupervised multitask learners. *OpenAI Technical Report*. https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf
7. **Zhang, C., Bengio, S., Hardt, M., Recht, B., & Vinyals, O.** (2017). Understanding deep learning requires rethinking generalization. *International Conference on Learning Representations (ICLR)*. https://arxiv.org/abs/1611.03530
8. **Kornblith, S., Norouzi, M., Lee, H., & Hinton, G.** (2019). Similarity of neural network representations revisited. *International Conference on Machine Learning (ICML)*, 3519-3529. https://arxiv.org/abs/1905.00414
9. **Su, J., Lu, Y., Pan, S., Murtadha, A., Wen, B., & Liu, Y.** (2024). RoFormer: Enhanced transformer with rotary position embedding. *Neurocomputing*, 568,

127063. https://arxiv.org/abs/2104.09864

10. **Ainslie, J., Lee-Thorp, J., de Jong, M., Zemlyanskiy, Y., Lebrón, F., & Sanghai, S.** (2023). GQA: Training generalized multi-query transformer models from multi-head checkpoints. *Proceedings of EMNLP*. https://arxiv.org/abs/2305.13245
11. **Shazeer, N., Mirhoseini, A., Maziarz, K., Davis, A., Le, Q., Hinton, G., & Dean, J.** (2017). Outrageously large neural networks: The sparsely-gated mixture-of-experts layer. *International Conference on Learning Representations (ICLR)*. https://arxiv.org/abs/1701.06538
12. **Qwen Team.** (2024). Qwen1.5 Technical Report. https://qwenlm.github.io/blog/qwen1.5/
13. **Shazeer, N.** (2019). Fast Transformer Decoding: One Write-Head is All You Need. *arXiv preprint*. https://arxiv.org/abs/1911.02150